



**ANALISIS SPATIO-TEMPORAL UNTUK DETEKSI  
SEBARAN HOTSPOT PADA RESTORASI AREA TERBAKAR  
MENGUNAKAN ALGORITMA RANDOM FOREST WITH  
SPARSE RANDOM PROJECTION DAN RANDOM  
MULTIMODEL ENSEMBLE**

**(STUDI KASUS: PERKEBUNAN SAWIT, KATINGAN  
KALIMANTAN TENGAH)**

**LAPORAN TUGAS AKHIR**

**AHMAD HELMY NURFAIZI**

**41820010118**

**PROGRAM STUDI SISTEM INFORMASI**

**FAKULTAS ILMU KOMPUTER**

**UNIVERSITAS MERCU BUANA**

**JAKARTA**

**2023**



**ANALISIS SPATIO-TEMPORAL UNTUK DETEKSI  
SEBARAN HOTSPOT PADA RESTORASI AREA TERBAKAR  
MENGUNAKAN ALGORITMA RANDOM FOREST WITH  
SPARSE RANDOM PROJECTION DAN RANDOM  
MULTIMODEL ENSEMBLE**

**(STUDI KASUS: PERKEBUNAN SAWIT, KATINGAN  
KALIMANTAN TENGAH)**

**LAPORAN TUGAS AKHIR**

**Diajukan Untuk Melengkapi Salah Satu Syarat  
Memperoleh Gelar Sarjana Komputer**

**AHMAD HELMY NURFAIZI**

**41820010118**

**PROGRAM STUDI SISTEM INFORMASI  
FAKULTAS ILMU KOMPUTER  
UNIVERSITAS MERCU BUANA  
JAKARTA**

**2023**

## **LEMBAR PERNYATAAN ORISINALITAS**

Yang bertanda tangan dibawah ini :

Nama : Ahmad Helmy Nurfaizi

NIM : 41820010118

Judul Tugas Akhir : ANALISIS SPATIO-TEMPORAL UNTUK DETEKSI  
SEBARAN HOTSPOT PADA RESTORASI AREA  
TERBAKAR MENGGUNAKAN ALGORITMA  
RANDOM FOREST WITH SPARSE RANDOM  
PROJECTION DAN RANDOM MULTIMODEL  
ENSEMBLE  
(STUDI KASUS: KATINGAN KALIMANTAN  
TENGAH)

Menyatakan bahwa Laporan Tugas Akhir saya adalah hasil karya sendiri dan bukan plagiat. Apabila ternyata ditemukan di dalam laporan Tugas Akhir saya terdapat unsur plagiat, maka saya siap untuk mendapatkan sanksi akademik yang terkait dengan hal tersebut.

Jakarta , 05 Desember 2023

Ahmad Helmy Nurfaizi

## LEMBAR PERSETUJUAN

### LEMBAR PERSETUJUAN

Nama Mahasiswa : Ahmad Helmy Nurfaizi  
NIM : 41820010118  
Judul Tugas Akhir : ANALISIS SPATIO-TEMPORAL UNTUK DETEKSI  
SEBARAN HOTSPOT PADA RESTORASI AREA TERBAKAR MENGGUNAKAN  
ALGORITMA RANDOM FOREST WITH SPARSE RANDOM PROJECTION DAN  
RANDOM MULTIMODEL ENSEMBLE  
(STUDI KASUS: PERKEBUNAN SAWIT, KATINGAN KALIMANTAN TENGAH)

Tugas Akhir ini telah diperiksa dan disetujui

Jakarta, 23 November 2023

Menyetujui,



(Dr. Ruci Meiyanti, S.Kom, M.Kom)

Dosen Pembimbing

## KATA PENGANTAR

Bacalah dengan (menyebut) nama Tuhanmu yang menciptakan,

Dia telah menciptakan manusia dari segumpal darah,

Bacalah, dan Tuhanmulah Yang Mahamulia,

Yang mengajar (manusia) dengan pena,

Dia mengajarkan manusia apa yang tidak diketahuinya.

QS.Al-Alaq 1-5

Saya ingin menyampaikan terimakasih yang sebesar besarnya kepada :

1. Ibu Dr. Ruci Meiyanti, M.Kom, selaku Kepala Program Studi Sistem Informasi Fakultas Ilmu Komputer dan selaku dosen pembimbing yang membimbing dalam penyusunan laporan tugas akhir ini
2. Bapak Haswadi, S.E., M.Si, selaku narasumber dari pihak Kementerian Lingkungan Hidup dan Kehutanan
3. Kedua Orang Tua dan Keluarga, yang selalu mendoakan dan memberikan dukungan secara moril dan materi
4. Teman-Teman Sistem Informasi, dan Sahabat BKB tersayang
5. Kepada mahasiswi yang memiliki Nim 41620010036 yang telah menemani penulis selama penyusunan dan telah menjadi rumah yang tidak hanya berupa tanah dan bangunan

Jakarta, 05 Desember 2023



Ahmad Helmy Nurfaizi

## ABSTRACT

Nama : Ahmad Helmy Nurfaizi  
NIM : 41820010118  
Pembimbing TA : Dr. Ruci Meiyanti, M.Kom  
Judul Tugas Akhir : Spatio-Temporal Analysis for Hotspot detection in restoration areas using the Random Forest With Sparse Random Projection algorithm and Random Multimodel Ensemble

The forest and land fires that occur in Indonesia can be considered as a regional and global disaster. The majority of these forest and land fires are the result of human activities related to deforestation. Specifically, in August 2019, at the oil palm plantation location in Katingan Regency, Central Kalimantan Province, an area of 970.44 hectares burned, causing economic losses and environmental damage. Therefore, there is a need for an effective and efficient method to estimate the severity of the burned area in order to implement recovery plans. Remote sensing is a method for mapping burned areas that is both effective and efficient in terms of time and cost. Remote sensing produces post-fire and pre-fire images obtained from Landsat satellite imagery, which are then processed using the Normalized Burn Ratio (NBR) index feature. The NBR method is used to assess the severity of fires in the restoration area. The implementation involves RFSRP (Random Forest with Sparse Random Projection) and Random Multimodel Ensemble to maximize the accuracy of the hotspot distribution map in the restoration area. This research aims to increase insights and knowledge about the factors influencing forest fires in companies in the plantation and agricultural sectors. It is also expected to serve as a means of developing theoretical knowledge studied in academic settings.

**Keywords:** Algorithm, Forest Fires, Hotspot, Restoration

## ABSTRAK

Nama : Ahmad Helmy Nurfaizi  
NIM : 41820010118  
Pembimbing TA : Dr. Ruci Meiyanti, M.Kom  
Judul Tugas Akhir : Analisis Spatio-Temporal untuk deteksi Hotspot pada area restorasi menggunakan algoritma Random Forest With Sparse Random Projection dan Random Multimodel Ensemble  
(Studi Kasus: Perkebunan Sawit,Katingan Kalimantan Tengah)

Kebakaran hutan dan lahan yang terjadi di Indonesia dapat dikatakan sebagai bencana regional dan global. Kebakaran hutan dan lahan yang terjadi sebagian besar merupakan hasil aktivitas kegiatan manusia yang berkaitan dengan deforestasi hutan. Tepatnya bulan Agustus tahun 2019 berlokasi perkebunan kelapa sawit di Kabupaten Katingan Provinsi Kalimantan Tengah seluas 970,44 hektar lahan yang terbakar menyebabkan kerugian ekonomi dan kerusakan lingkungan hidup. Sehingga perlu adanya cara yang efektif dan efisien untuk memperkirakan seberapa parah area yang terbakar untuk menerapkan rencana pemulihan dari area tersebut. Remote sensing merupakan metode untuk memetakan area yang terbakar yang efektif dan efisien baik dari segi waktu maupun biaya. Remote sensing menghasilkan gambar pasca-kebakaran dan pra-kebakaran diperoleh dari citra satelit Landsat yang kemudian diolah dengan menggunakan fitur index NBR (Normalized Burn Ratio). Menggunakan metode NBR guna mencari tingkat keparahan kebakaran pada daerah restorasi. Mengimplementasikan RFSRP (Random Forest with Sparse Random Projection) dan Random Multimodel Ensemble. Bertujuan memaksimalkan nilai akurasi pada peta sebaran hotspot daerah restorasi. Penelitian ini diharapkan dapat menambah wawasan dan pengetahuan mengenai faktor-faktor yang mempengaruhi kebakaran hutan pada perusahaan sektor perkebunan, pertanian serta juga diharapkan sebagai sarana pengembangan ilmu pengetahuan yang secara teoritis dipelajari di bangku perkuliahan.

**Kata Kunci :** Algoritma, Kebakaran Hutan, Hotspot, Restorasi

## DAFTAR ISI

HALAMAN JUDUL.....	i
LEMBAR PERNYATAAN ORISINALITAS .....	i
LEMBAR PERSETUJUAN.....	iii
KATA PENGANTAR .....	iv
ABSTRACT.....	v
ABSTRAK .....	vi
DAFTAR ISI.....	vii
DAFTAR TABEL.....	ix
DAFTAR GAMBAR .....	x
DAFTAR LAMPIRAN.....	xi
BAB I PENDAHULUAN.....	12
1.1    Latar Belakang .....	12
1.2    Permasalahan.....	15
1.3 Tujuan Penelitian .....	15
1.4 Batasan Masalah.....	16
1.5    Manfaat Penelitian .....	16
1.6 Sistematika Penulisan .....	17
BAB II LANDASAN TEORI .....	19
2.1    Teori Remote Sensing .....	19
2.2    Teori Geographic Information System (GIS) .....	20
2.3    Teori Citra Landsat 8 .....	21
2.4    Teori Kebakaran Hutan .....	24
2.5    Teori Restorasi .....	25
2.6    Teori Normalized Burn Ratio (NBR).....	27
2.7    Teori Random Forest.....	30
2.8    Random Forest With Sparse Random Projection (RFSR) .....	32
2.9    Teori Random Multimodel Esemble.....	34
2.10    Teori Confusion Matrix.....	36
BAB III METODE PENELITIAN.....	64
3.1    Lokasi Penelitian.....	64
3.2    Sarana Pendukung .....	65
3.3    Teknik Pengumpulan Data .....	65



3.4	Diagram Alir .....	67
3.5	Timeline Penelitian .....	69
BAB IV HASIL DAN PEMBAHASAN .....		70
4.1	Analisa Fishbone .....	70
4.2	Pengumpulan Data .....	70
4.2.1	Pre-Processing.....	71
4.3	Ekstrasi Fitur .....	71
4.3.1	Ektrasi Fitur Normalized Burn Ratio (NBR) .....	71
4.4	Pemodelan .....	72
4.4.1	Pemodelan Random Forest With Sparse Random Projection untuk Normalized Burn Ratio .....	73
4.4.2	Pemodelan Random Multimodel Ensemble.....	76
4.4.3	Visualisasi .....	79
4.5	Implikasi Bisnis.....	81
BAB V KESIMPULAN DAN SARAN.....		82
5.1	Kesimpulan .....	82
5.2	Saran.....	82
DAFTAR PUSTAKA .....		84
LAMPIRAN.....		87

## DAFTAR TABEL

Tabel 2. 1 Landsat 8 Band Designations.....	23
Tabel 2. 2 Severty Levels NBR .....	30
Tabel 2. 3 Literature Review .....	44
Tabel 2. 4 Jumlah Jurnal per Tahun untuk Critical Analisis.....	56

## DAFTAR GAMBAR

Gambar 1. 1 Data Grafik Titik Panas Landsat 8 Tahun 2020 .....	13
Gambar 2. 1 Sistem Penginderaan Jarak Jauh .....	<b>Error! Bookmark not defined.</b>
Gambar 2. 2 GIS .....	<b>Error! Bookmark not defined.</b>
Gambar 2. 3 Citra Landsat .....	24
Gambar 2. 4 Kebakaran Hutan .....	25
Gambar 2. 5 Restorasi .....	26
Gambar 2. 6 Mosaic Dataset .....	27
Gambar 2. 7 Normalized Burn Ratio (NBR) .....	29
Gambar 2. 8 Algoritma Random Forest .....	32
Gambar 2. 9 Algoritma Sparse Random Projection .....	34
Gambar 2. 10 Algoritma Random Multimodel Ensemble .....	35
Gambar 2. 11 Rumus Matrix .....	36
Gambar 2. 12 Critical Analisis dengan Vosviewer .....	57
Gambar 2. 13 GAP Penelitian .....	61
Gambar 3. 1 Lokasi Penelitian .....	64
Gambar 3. 2 Metodologi Penelitian .....	67
Gambar 3. 3 Timeline Penelitian .....	69
Gambar 4. 1 Diagram Fishbone .....	<b>Error! Bookmark not defined.</b>
Gambar 4. 2 Pre-Processing .....	71
Gambar 4. 3 Visualisasi Normalized Burn Ratio .....	72
Gambar 4. 4 Dataset NBR .....	73
Gambar 4. 5 Dataset NBR .....	73
Gambar 4. 6 Model Algoritma .....	74
Gambar 4. 7 Scoring RFSRP .....	75
Gambar 4. 8 Akurasi RFWSRP .....	75
Gambar 4. 9 Classifitacion Report .....	76
Gambar 4. 10 Dataset NBR .....	76
Gambar 4. 11 Pembagian Data Training dan Testing RME .....	77
Gambar 4. 12 Model Algoritma Random Multimodel Ensemble (RME) .....	77
Gambar 4. 13 Scoring RME .....	78
Gambar 4. 14 Akurasi RME .....	78
Gambar 4. 15 Classification Report .....	79
Gambar 4. 16 Scatter Plot Menggunakan Algoritma RFSRP .....	79
Gambar 4. 17 Heatmap Menggunakan Algoritma RFSRP .....	80
Gambar 4. 18 visualisasi scatter plot menggunakan algoritma RME .....	80
Gambar 4. 19 Visualisasi Heatmap menggunakan algoritma RME .....	81

## DAFTAR LAMPIRAN

Lampiran 1 Data Narasumber .....	87
Lampiran 2 Surat pendukung penelitian .....	88
Lampiran 3 Hasil Interview .....	89

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Kebakaran hutan sering kali terjadi di Indonesia pada saat musim kemarau, apalagi Indonesia salah satu negara paru paru dunia karena memiliki total luas hutan sebesar 128 juta Ha yang membuat Indonesia menjadi negara penghasil oksigen terbesar ke-2 di dunia dan negara yang mampu menyimpan karbon karena tutupan lahan yang sangat besar[1] Kebakaran terjadi di hutan, pertanian, dan area bekas lainnya. Kebakaran tersebut menimbulkan dampak negatif terhadap lingkungan, sosial dan ekonomi. Konteksnya adalah penyebab kebakaran, lokasi kebakaran, dan dampak kebakaran. Indonesia mengalami kerugian hingga Rp 209 triliun pada tahun 2015. Musim kemarau menjadi salah satu faktor penyebab kebakaran hutan. Tentu saja kebakaran ini akan berdampak pada beberapa bidang seperti kesehatan, perekonomian dan sosial. Dan kebakaran yang sering terjadi di hutan-hutan Indonesia dan menimbulkan asap yang berlebihan, tentu saja berbahaya dan merugikan masyarakat yang terkena dampaknya.

Kebakaran Hutan memiliki dampak sebagai berikut:

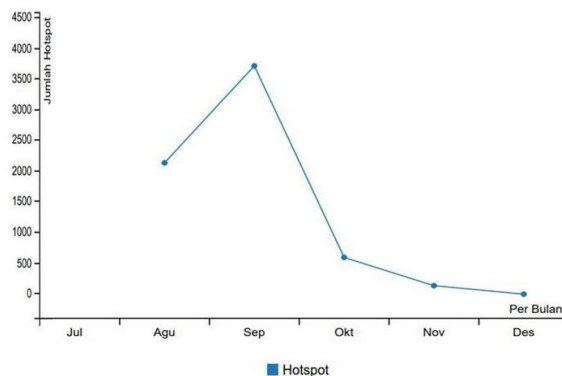
- a. Rusaknya ekosistem yang menyebabkan punahnya flora dan fauna yang hidup di hutan.
- b. Asap kebakaran yang merupakan polusi udara yang dapat menyebabkan penyakit ISPA
- c. Kabut asap yang mengganggu jarak pandang transportasi baik darat maupun udara
- d. Tersebarnya asap yang mengandung emisi gas Karbondioksida dan gas-gas lain
- e. Hutan menjadi gundul dan dapat menyebabkan bencana longsor dan banjir

Pemulihan lahan setelah kebakaran Itu pasti tidak dapat berjalan sendirian. Diperlukan tindakan yang tepat untuk memastikan kondisi lahan gambut tetap baik, mulai dari daerah mana pun yang akan direstorasi.. Dari mulai pemilihan jenis tanaman dan jenis tanah yang cocok untuk di tanami kembali pasca kebakaran yang memakan waktu cukup lama untuk kembali seperti semula. Faktor pendukung restorasi pada tanaman :

- Biotic : fungal communities, grass and shrub competition
- Abiotic : topography, slope, moisture environments

Fokus penelitian ini adalah menitik beratkan pada pemulihan lahan atau restorasi setelah kebakaran. Diperlukan tindakan yang tepat untuk memastikan kondisi lahan yang baik, Langkah itu bisa dimulai dari mengetahui sebaran hotspot dengan akurat untuk mengetahui wilayah yang akan di restorasi.

Data Matrik Titik Panas LANDSAT8 (LAPAN) High Tahun 2020



Gambar 1. 1 Grafik Titik Panas Landsat8 2020

Gambar 1.1 menjelaskan data titik panas diidentifikasi menggunakan *landsat 8* pada tahun 2020 di bulan September menjadi grafik yang paling naik signifikan tingkat kebakaran di wilayah Katingan Kalimantan Tengah dibandingkan dengan bulan sebelumnya. Titik panas mulai mereda di bulan Oktober hingga akhirnya menurun drastis di bulan Desember 2020.

Informasi tentang kebakaran hutan di daerah Kalimantan tengah yang banyak terjadi hanya memunculkan dampak dari kebakaran tersebut dan tidak

adanya penelitian tentang sebaran titik panas pada daerah yang terbakar secara akurat untuk restorasi yang lebih baik.

*Hotspot* atau titik api adalah suatu titik atau wilayah di mana terjadi kebakaran hutan atau lahan yang menghasilkan asap yang dapat membahayakan kesehatan dan lingkungan.[2] Oleh karena itu, pemetaan area sebaran *hotspot* sangat penting untuk mendukung upaya pengendalian kebakaran hutan dan lahan serta untuk membantu memulihkan hutan yang rusak.[3]

Untuk melakukan pemetaan area sebaran *hotspot*, penelitian tersebut menggunakan algoritma *Random Forest with Sparse Random Projection* dan *Random Multimodel Ensemble*, yang merupakan algoritma *machine learning* yang digunakan untuk klasifikasi[4]. Klasifikasi ini akan memetakan area sebaran *hotspot* dengan akurasi yang tinggi, sehingga dapat digunakan sebagai dasar untuk merencanakan program restorasi hutan di Kalimantan Tengah dengan lebih akurat.

Ekstraksi fitur yang digunakan di dalam penelitian ini yaitu *Normalized Burn Ratio* (NBR). *Normalized Burn Ratio* (NBR) Merupakan indeks yang dirancang untuk mengidentifikasi daerah yang terbakar. Karena pada kasus kebakaran hutan yang terjadi harus dilihat juga dari tingkat keparahan yang disebabkan oleh kebakaran maka *Normalized Burn Ratio* (NBR) dianggap sebagai standar untuk penilaian keparahan kebakaran[5]. Dimana nilai NBR yang tinggi pada umumnya menunjukkan vegetasi yang sehat, dan nilai yang rendah menunjukkan tanah kosong dan area yang baru saja terbakar.

Algoritma yang digunakan adalah *Random Forest*, *Random forest* adalah pengembangan dari metode *decision tree*, *random forest* memiliki beberapa kelebihan yaitu dapat meningkatkan hasil akurasi jika terdapat data yang hilang dan untuk *resisting outliers*, serta efisien dalam penyimpanan sebuah data[4]. Algoritma *Random forest* akan digabungkan dengan algoritma *sparse random projection*. *Sparse Random Projection* dapat digunakan untuk mengurangi dimensi data dalam berbagai aplikasi seperti pengolahan bahasa alami, pengenalan gambar, pengenalan suara, dan lain-lain. Teknik ini

membantu mengurangi waktu komputasi dan penggunaan memori yang dibutuhkan dalam pelatihan model *machine learning* dan meningkatkan efisiensi dan kinerja model. Dan menurut dari penelitian sebelumnya yang penulis baca, penggunaan algoritma *random forest with sparse random projection* bisa menghasilkan akurasi yang lebih baik.

Selain menggunakan algoritma *random forest with sparse random projection*, penulis juga menggunakan algoritma *random multimodel esemble* di dalam penulisan ini. Algoritma *Random Multimodel Ensemble* (RME) adalah sebuah metode yang digunakan untuk meningkatkan performa atau akurasi dari *model machine learning* dengan menggabungkan beberapa model yang berbeda ke dalam sebuah *ensemble model*.

Berdasarkan uraian di atas maka dengan ini penulis dapat memaparkan hasil dari penelitian yang telah penulis lakukan dalam bentuk Laporan Tugas Akhir dengan judul “ Analisis Spatio-Temporal untuk deteksi Sebaran Hotspot pada Restorasi Area Terbakar Menggunakan Algoritma Random Forest With Sparse Random Projection dan Random Multimodel Ensemble (Studi Kasus: Perkebunan Sawit, Katingan Kalimantan Tengah).

## 1.2 Permasalahan

Berdasarkan uraian latar belakang diatas, Maka di dalam penelitian ini penulis memiliki beberapa perumusan masalah sebagai berikut:

1. bagaimana tingkat keparahan kebakaran pada restorasi area terbakar menggunakan NBR?
2. Bagaimana akurasi dari hasil klasifikasi area sebaran *hotspot* yang dilakukan menggunakan *algoritma Random Forest with sparse random projection* ?
3. Bagaimana akurasi dari hasil klasifikasi area sebaran *hotspot* yang dilakukan menggunakan algoritma *Random Multimodel Esemble*?

## 1.3 Tujuan Penelitian

Dalam penelitian ini penulis menemukan tujuan penelitian adalah sebagai berikut:



1. Menggunakan metode NBR untuk mencari tingkat keparahan kebakaran pada daerah restorasi area terbakar
2. Mengevaluasi performa algoritma *Random Forest with Sparse Random Projection* dalam klasifikasi area sebaran *hotspot* di Perkebunan Sawit Katingan Kalimantan Tengah
3. Mengevaluasi performa algoritma *Random Multimodel ensemble* dalam klasifikasi area sebaran *hotspot* di Perkebunan Sawit Katingan Kalimantan Tengah

#### **1.4 Batasan Masalah**

1. Penelitian ini hanya akan fokus pada klasifikasi area sebaran *hotspot* di wilayah Perkebunan Sawit, Katingan Kalimantan Tengah.
2. Metode yang digunakan untuk melakukan klasifikasi area sebaran hotspot adalah algoritma *Random Forest With Sparse Random Projection* dan *Random Multimodel Esemble*
3. Tujuan penggunaan hasil klasifikasi adalah untuk mendukung upaya restorasi hutan di wilayah Kalimantan Tengah
4. Penelitian ini hanya menampilkan akurasi dari hasil dua algoritma dan tidak untuk membandingkan akurasi dari hasil kedua algoritma tersebut
5. Hanya menggunakan Ekstrasi Fitur *Normalized Burn Ratio* (NBR)
6. Penelitian ini hanya menggunakan Citra Landsat-8 dengan Band 4 dan 6
7. Penelitian ini tidak akan membahas secara mendalam tentang faktor-faktor penyebab terjadinya hotspot di wilayah Kalimantan Tengah, melainkan hanya sebatas identifikasi faktor-faktor yang mempengaruhi sebaran hotspot dan restorasi hutan di wilayah tersebut.

#### **1.5 Manfaat Penelitian**

##### **Teoritis**

Penelitian ini di harapkan dapat memberikan dasar bagi pengembangan teori restorasi hutan, khususnya di Kalimantan Tengah. Pemetaan area sebaran *hotspot* yang akurat dapat membantu merencanakan program restorasi hutan yang lebih efektif dan efisien. Selain itu Metode ini dapat diaplikasikan pada

penelitian lain dan membuka peluang untuk pengembangan metode pemetaan lainnya yang lebih akurat.

### **Praktis**

Bagi penulis Penelitian ini diharapkan dapat menjadi sarana yang bermanfaat dan dapat membantu menghasilkan data yang lebih akurat tentang sebaran *hotspot*, yang dapat digunakan sebagai dasar untuk merancang program restorasi hutan yang efektif dan efisien.

## **1.6 Sistematika Penulisan**

Laporan tugas akhir ini terdiri dari 5 bab, masing-masing terdiri dari beberapa sub bab yang dapat diuraikan kembali. Sistematika yang digunakan untuk menulis laporan tugas akhir adalah sebagai berikut.:

### **BAB I : PENDAHULUAN**

Penulis memberikan ringkasan umum tentang proses penyusunan Proposal Tugas Akhir dalam bab pertama. Ini mencakup penjelasan tentang latar belakang, proses membuat rumusan masalah, batasan masalah, tujuan dan keuntungan penelitian, serta prosedur penulisan yang sistematis yang menjelaskan pokok-pokok atau garis besar penulisan..

### **BAB II : TINJAUAN PUSTAKA**

Pada bab kedua, penulis menjelaskan tentang teori-teori yang berkaitan dengan *kebakaran, proses restorasi, tingkatan keparahan*. Tak lupa penulis juga menjelaskan tentang teori-teori pendukungnya berupa teori *Geographic Information System, Remote Sensing* dan *Citra Landsat 8*. Serta akan dijelaskan tentang *Critical review* dari beberapa penelitian terdahulu.

### **BAB III : METODE PENELITIAN**

Pada bab ketiga, penulis menjelaskan tentang alur atau metodologi penelitian

### **BAB IV : HASIL DAN PEMBAHASAN**

Pada bab keempat ini, berisikan hasil yang didapatkan dari penelitian oleh penulis serta pembahasannya.

## BAB V : KESIMPULAN DAN SARAN

Pada bab terakhir ini, berisikan kesimpulan dari laporan yang telah penulis rangkai dan saran yang diberikan untuk penelitian berikutnya.

## **BAB II**

### **LANDASAN TEORI**

#### **2.1 Teori Remote Sensing**


Penginderaan jarak jauh (remote sensing)

"ilmu untuk memperoleh informasi tentang suatu objek, daerah, fenomena melalui analisis data yang diperoleh dengan alat tanpa kontak langsung dengan objek daerah atau fenomena yang dikaji" [6]

Teori tersebut juga mencakup beberapa prinsip dasar yang berkaitan dengan pengumpulan data, analisis data, dan interpretasi data. Prinsip-prinsip dasar ini mencakup interaksi antara pancaran radiasi elektromagnetik dan permukaan bumi, perlunya mempertimbangkan karakteristik satelit seperti resolusi spasial dan temporal ketika memilih satelit untuk keperluan pengumpulan data, dan perlunya interpretasi data, termasuk pola, deteksi objek, klasifikasi dan segmentasi.[7]

Sistem sensor aktif mengumpulkan data radar dan kontur, sementara sistem sensor pasif mengumpulkan data citra optik dari satelit.[6]


Energi ini berinteraksi dengan objek sasaran tergantung pada jenis objek dan energi yang dipancarkannya. Setelah energi dihamburkan atau dipancarkan dari objek target, sensor mengumpulkan dan merekam radiasi elektromagnetik dari jarak jauh tanpa menyentuh objek target. Informasi yang ditangkap oleh sensor dikirim ke stasiun penerima dan pemrosesan untuk diproses menjadi gambar digital atau cetak. Gambar tersebut kemudian diinterpretasikan secara visual atau digital untuk mendapatkan data tentang objek yang dimaksud.[6] Dalam penginderaan jarak jauh, tahap terakhir adalah menggunakan data yang diperoleh untuk mencari informasi baru atau membantu menyelesaikan masalah.[8]



*Gambar 2. 1 Remote Sensing*

## 2.2 Teori Geographic Information System (GIS)

*Geographic Information System (GIS)* atau Sistem Informasi Geografis adalah sebuah teknologi yang memungkinkan User untuk mengumpulkan, mengelola, menganalisis, dan memvisualisasikan informasi yang terkait



dengan lokasi atau ruang pada peta digital.[9] GIS (*Geography Information System*) memiliki 2 model data yaitu data raster dan data vector.

Data raster adalah jenis data geospasial yang merepresentasikan suatu area atau wilayah dengan menggunakan matriks piksel (titik gambar) dalam bentuk grid atau matrix yang terdiri dari sel-sel berukuran sama. Setiap piksel dalam grid memiliki nilai atau atribut yang mewakili karakteristik tertentu di lokasi tersebut, seperti warna, elevasi, suhu, kepadatan, atau jenis tanah[9]

Data vektor adalah jenis data geospasial yang merepresentasikan suatu area atau wilayah dengan menggunakan objek geometri, seperti titik, garis, atau poligon, yang saling terhubung membentuk suatu jaringan.[9] Setiap objek dalam data vektor memiliki atribut atau nilai yang menggambarkan karakteristik tertentu di lokasi tersebut, seperti nama jalan, jenis tanah, ketinggian, atau jumlah penduduk. Data vektor biasanya digunakan untuk merepresentasikan data yang diskrit atau berkelompok.[10]

### 2.3 Teori Citra Landsat 8

#### *Gambar 2. 2 GIS*

*Landsat Data Continuty Mission* (LDCM). satelit ini kemudian lebih dikenal sebagai Landsat8 yang memiliki tujuan untuk mengumpulkan data citra bumi untuk membantu memahami tentang lingkungan alam dan memantau perubahan alam.[1]

Landsat 8 diluncurkan dari VAFB, California pada tahun 2011 menggunakan pesawat berbasis kapal induk Atlas V401. Landsat8 dirancang untuk orbit dekat matahari sinkron dengan ketinggian 705 km, kemiringan 98,2 derajat, jangka waktu 99 menit, resolusi waktu 16 hari, dan waktu penyeberangan ekuator pukul 10.00 hingga 10.15. Landsat 8 dilengkapi dengan Operational Land Imager (OLI) dan Thermal Independent Sensor (TIRS).

Sensor OLI memiliki 9 saluran, terdiri dari 1 saluran inframerah dekat, 7 refleksi tampak, dan 1 saluran deteksi awan cirrus. Sensor TIRS memiliki 2 saluran termal untuk memastikan bahwa data dari saluran inframerah termal

yang tidak terdeteksi oleh sensor OLI tetap konsisten. Adanya saluran (Band) panjang gelombang elektromagnetik yang dapat mendeteksi radiasi matahari adalah ciri utama citra dalam penginderaan jauh.[11] Band ini termasuk panjang gelombang elektromagnetik inframerah, pankromatik, dan termal yang dipantulkan oleh material di permukaan bumi.[12]. Tiap benda/substansi memiliki reflektivitas yang berbeda terhadap cahaya matahari, sehingga nilainya pada setiap wavelength elektromagnetik akan beragam.

Landsat8 mencakup beberapa konsep seperti *spektrum elektromagnetik* yang berfungsi untuk mengumpulkan data citra dengan menggunakan sensor satelit yang dapat mendeteksi radiasi elektromagnetik dalam rentang spektrum yang lebar.[13] Ini termasuk sinar inframerah, sinar tampak, dan sinar ultraviolet.

Tabel 2. 1 Landsat 8 Band Designations

Resolusi spasial, Landsat 8 mengumpulkan data citra resolusi spasial tinggi, memungkinkan satelit untuk melihat area kecil secara detail. Hal ini memungkinkan pemahaman yang lebih mendalam tentang perubahan lingkungan. Resolusi temporal menangkap data gambar secara berkala, memungkinkan memantau perubahan alami dari waktu ke waktu. Koreksi Atmosfer Perbedaan kondisi atmosfer pada saat pengambilan gambar dapat menyebabkan perbedaan kualitas gambar. Gambar Landsat 8 disempurnakan

<b>Band</b>	<b>Resolusi Spasial</b>	<b>Panjang Gelombang</b>	<b>Fungsi</b>
Band 1 Coastal aerosol	30 Meter	0,43 - 0,45 $\mu\text{m}$	Deteksi pesisir dan air laut
Band 2 Blue	30 Meter	0,45 - 0,51 $\mu\text{m}$	Pemetaan batimetri; membedakan <i>soil</i> dari vegetasi
Band 3 Green	30 Meter	0,53 - 0,59 $\mu\text{m}$	Deteksi ketahanan vegetasi
Band 4 Red	30 Meter	0,64 - 0,67 $\mu\text{m}$	Membedakan jenis vegetasi
Band 5 Near Infrared	30 Meter	0,85 - 0,88 $\mu\text{m}$	Deteksi biomassa dan garis pantai
Band 6 SWIR 1	30 Meter	1,57 - 1,65 $\mu\text{m}$	Deteksi kelembaban <i>soil</i> & tumbuhan
Band 7 SWIR 2	30 Meter	2,11 - 2,29 $\mu\text{m}$	Deteksi kelembaban <i>soil</i> & tumbuhan
Band 8 Panchromatic	15 Meter	0,50 - 0,68 $\mu\text{m}$	Mempertajam citra
Band 9 Cirrus	30 Meter	1,36 - 1,38 $\mu\text{m}$	Deteksi awan <i>cirrus</i>
Band 10 TIRS 1	100 Meter	10,60 - 11,19 $\mu\text{m}$	Deteksi panas/sebaran temperatur
Band 11 TIRS 2	100 Meter	11,50 - 12,51 $\mu\text{m}$	Deteksi panas/sebaran temperatur



menggunakan algoritma koreksi atmosfer untuk meningkatkan kualitas gambar dan akurasi pemrosesan.[1]



*Gambar 2. 3 Citra Landsat*

## 2.4 Teori Kebakaran Hutan

Kebakaran hutan merupakan fenomena terjadinya kebakaran berskala besar yang terjadi di hutan atau ladang[14]. Kebakaran hutan biasanya disebabkan oleh faktor alam seperti sambaran petir, atau faktor manusia seperti terbakarnya lahan untuk perkebunan atau pertanian. Kebakaran hutan dan lahan merupakan kejadian berulang, biasanya terjadi selama musim kemarau di hutan yang dikelola pemerintah atau lahan milik masyarakat.[15]

Parameter biofisik yang mempengaruhi Risiko kebakaran hutan dan lahan mencakup berbagai faktor, termasuk cuaca dan iklim, bahan bakar, vegetasi, dan kondisi lahan. Dalam kasus ini, curah hujan merupakan representasi dari cuaca dan iklim, dan indeks vegetasi merupakan representasi dari kondisi vegetasi. Kebakaran hutan dapat muncul dengan cepat dan menyebar menjadi kebakaran besar karena jenis dan perilaku bahan bakar, topografi, iklim, dan aspek lain yang mempengaruhi dinamika kebakaran. Oleh karena itu, penting untuk mengendalikan dan mencegah kebakaran hutan dengan melakukan tindakan seperti pemadaman kebakaran, pengawasan, dan patroli, serta memberi tahu masyarakat tentang bahaya kebakaran hutan. Kebakaran hutan berdampak buruk pada lingkungan dan manusia. [16]. Dampaknya dapat

berupa kerusakan ekosistem, kehilangan keanekaragaman hayati, penurunan kualitas udara, bahkan berdampak pada kesehatan manusia seperti gangguan pernapasan.[15]



*Gambar 2. 4 Kebakaran Hutan*


## **2.5 Teori Restorasi**

Restorasi hutan adalah upaya pemulihan kondisi hutan dan ekosistem di daerah yang telah mengalami kerusakan atau degradasi akibat aktivitas manusia, seperti penebangan hutan yang berlebihan, kebakaran hutan, pertanian dan perkebunan yang tidak berkelanjutan, dan sejenisnya.[17]

Restorasi juga mencakup kegiatan yang bertujuan untuk mempertahankan pengelolaan suaka alam dan cagar alam. Salah satu kegiatan konservasi yang dimaksud adalah restorasi ekosistem yang dimulai dengan restorasi fungsi, struktur, dinamika populasi, keanekaragaman hayati, dan ekosistem. Dalam melakukan restorasi harus memperhatikan kondisi hutan, jenis hutan yang direstorasi, dan kesesuaian tanah.[18]. Tujuan dari restorasi hutan adalah untuk memperbaiki ekologi hutan, termasuk menyerap karbondioksida dari atmosfer dan menyimpannya dalam tanaman dan tanah, meningkatkan keanekaragaman hayati dan menyediakan habitat yang lebih baik bagi satwa liar untuk membantu mitigasi perubahan iklim. Tujuannya adalah untuk memulihkan fungsi Hutan dengan baik .Mampu memberikan manfaat ekonomi, sosial dan lingkungan yang berkelanjutan, yaitu manfaat restorasi penting juga untuk

mengurangi dampak perubahan iklim, melestarikan keanekaragaman hayati, menghasilkan manfaat ekonomi dan meningkatkan kualitas air dan udara.[17]

Banyak pemangku kepentingan yang terlibat dalam restorasi hutan, termasuk pemerintah, masyarakat lokal, dan organisasi non-pemerintah.[19] Restorasi tidak akan optimal jika hanya melibatkan satu orang atau beberapa pihak dalam restorasi. Oleh karena itu, dukungan dan partisipasi seluruh pemangku kepentingan sangat penting untuk mencapai hasil restorasi hutan yang optimal.[17]




*Gambar 2. 5 Restorasi*

### **Ekstraksi Fitur**

Ekstraksi fitur (feature extraction) adalah proses mengubah data yang kompleks menjadi representasi yang lebih sederhana namun tetap mempertahankan informasi yang penting.[20] Tujuannya adalah untuk memperoleh informasi yang lebih bermakna atau lebih mudah diolah dalam

konteks tertentu. Ekstraksi fitur adalah teknik yang mengurangi dimensi data dan meningkatkan performa model. Hal ini dilakukan dengan mengidentifikasi fitur-fitur terpenting dalam kumpulan data dan menghapus fitur-fitur yang tidak penting atau berlebihan. Dalam ekstraksi fitur, kumpulan data mosaik adalah jenis kumpulan data spasial sistem informasi geografis (GIS) yang terdiri dari kumpulan data raster yang dikelompokkan ke dalam kumpulan data. Kumpulan data mosaik biasanya digunakan untuk mengelola sejumlah besar data raster yang saling berhubungan di satu tempat yang dapat diakses dan dilihat dengan mudah.

Data raster terkait dapat digabungkan menjadi satu kumpulan data yang terdiri dari beberapa lapisan dengan atribut terkait seperti tanggal akuisisi, jenis sensor, dan resolusi spasial.



*Gambar 2. 6 Mosaic Dataset*

## 2.6 Teori Normalized Burn Ratio (NBR)

Burn area dapat didefinisikan sebagai daerah di permukaan bumi yang menunjukkan bahwa telah terbakar oleh proses alami atau oleh manusia secara disengaja atau tidak disengaja..[15] Kawasan ini dulunya terdiri dari vegetasi hutan dan non-hutan, tetapi sekarang menjadi endapan arang dan abu akibat pembakaran tutupan vegetasi dan bahan bakar lainnya., serta adanya tanah terbuka dipermukaan. Perubahan kondisi tanah dari yang tadinya bervegetasi menjadi tidak bervegetasi dapat diidentifikasi dengan menggunakan citra penginderaan jauh dan observasi lapangan. Area yang terbakar berbeda dengan

Hotspot. Hotspot menunjukkan kemungkinan terjadinya kebakaran, namun tidak menjamin terjadinya kebakaran. [21]. Dengan kata lain, area yang terbakar adalah kebakaran sebenarnya, sedangkan Hotspot adalah kebakaran potensial. Normalized Burn Ratio (NBR) adalah algoritma untuk mengevaluasi besaran api atau luas area yang terbakar. Ini adalah indeks yang banyak digunakan yang berasal dari foto udara dan citra. Perbandingan pita inframerah dekat (NIR) dan inframerah gelombang pendek (SW) dari perhitungan NBR citra satelit.

Perbandingannya dilakukan dengan mengurangkan pita SWIR dengan pita NIR dan membagi hasilnya dengan jumlah pita.[5]. NBR terutama untuk mengidentifikasi tingkat kerusakan vegetasi akibat kebakaran. Fungsi NBR adalah untuk mendeteksi dan membedakan antara area yang tidak terbakar dan yang terbakar bahkan dalam ekosistem yang kompleks seperti hutan yang selalu hijau atau gugur.[22] Ketika terjadi kebakaran tutupan vegetasi menyerap lebih sedikit cahaya, yang menyebabkan penurunan band NIR dan peningkatan band SWIR, sehingga menghasilkan nilai N yang rendah. Pada penggunaan NBR di citra Landsat8, band yang digunakan adalah band 5 dan band 7.

Secara teoritis, rasio pembakaran normal (NBR) dimaksudkan untuk menunjukkan area yang terbakar dengan menunjukkan penurunan nilai NBR yang signifikan pada area tertentu setelah kebakaran.[23] Nilai NBR juga dimaksudkan untuk menunjukkan area yang terbakar dan memperkirakan tingkat keparahan kebakaran.[5]. Setelah api padam, terjadi regenerasi tutupan vegetasi yang menyebabkan peningkatan band NIR dan penurunan SWIR. Akibatnya, nilai NBR meningkat. Tingkat regenerasi tergantung pada tingkat keparahan kebakaran, dan BR memberikan ukuran kuantitatif yang dapat digunakan untuk memperkirakan kerusakan akibat kebakaran.

Intinya NBR adalah alat penting untuk mendeteksi luas dan parahnya kerusakan yang disebabkan oleh kebakaran yang memungkinkan respons tepat waktu dan pengelolaan pemulihan[5]. Metode Normalized Burn Ratio (NBR) menggunakan persamaan berikut :


$$NBR = \frac{NIR - SWIR}{NIR + SWIR}$$

Keterangan :

NBR : Normalized Burn Ratio

NIR : Nilai Spektral Saluran InfraRed

SWIR : Nilai Spektral Saluran Short WaveLenght InfraRed



*Gambar 2. 7 Normalized Burn Ratio (NBR)*



Tabel 2. 2 Severty Levels NBR

$\Delta NBR$	Burn Severity
< -0.25	High post-fire regrowth
-0.25 to -0.1	Low post-fire regrowth
-0.1 to +0.1	Unburned
0.1 to 0.27	Low-severity burn
0.27 to 0.44	Moderate-low severity burn
0.44 to 0.66	Moderate-high severity burn
> 0.66	High-severity burn

## 2.7 Teori Random Forest

Salah satu metode ilmiah kontemporer, machine learning, memiliki kemampuan untuk melakukan prosedur otomatis untuk membuat prediksi fenomena dengan memanfaatkan pengamatan kejadian sebelumnya untuk menemukan pola dalam kumpulan data yang diberikan.[24] Makin banyak orang sekarang menggunakan machine learning untuk menyelesaikan tugas atau masalah sehari-hari yang membutuhkan proses ekstraksi data yang besar. Ada dua jenis pengajaran mesin: Supervised Learning dan Unsupervised Learning. Pengajaran yang diawasi mengacu pada pengajaran mesin yang diberi label output yang harus dikeluarkan mesin. Pengajaran yang tidak diawasi mengacu pada pengajaran mesin yang belajar dari data yang tidak diberi label output.[4]

Random Forest adalah algoritma pembelajaran supervised yang dibuat oleh Breiman pada tahun 2001. machine learning yang digunakan untuk memproses set data.[13] Algoritma ini menggabungkan beberapa pohon keputusan (decision tree) yang dibangun dengan cara acak pada sub-sampel data yang diambil dari set data utama. Setiap pohon keputusan memiliki bobot yang sama dan diambil hasil voting mayoritas sebagai hasil akhir serta memiliki kemampuan untuk menemukan fitur-fitur penting (feature selection) dalam set data.

Random Forest biasanya digunakan untuk menyelesaikan masalah seperti klasifikasi, regresi, dan sebagainya.[4] Algoritma ini disebut secara acak karena dua hal:

1. Setiap pohon diambil dari data latih secara acak dan ditanam pada sampel bootstrap yang berbeda
2. Selama pembentukan pohon keputusan, sebagian sampel dari variable  $m$  dipilih dari kumpulan data asli dan kemudian digunakan dalam node tersebut.

Algoritma ini adalah kombinasi dari beberapa pohon keputusan atau pohon prediktor. Nilai vektor acak yang diambil sampelnya secara bebas dan merata dari semua pohon di hutan tersebut memengaruhi setiap pohon. Jumlah hasil maksimum dari masing-masing pohon keputusan individu (voting untuk klasifikasi dan rata-rata untuk regresi) adalah hasil prediksi dari Random Forest. Algoritma hutan acak melibatkan beberapa langkah kerja: berbagi data, membuat pohon keputusan, menyelesaikan masalah overfitting, mengkombinasikan decision tree, menggabungkan pohon keputusan, dan mengevaluasi kinerja model. Hutan acak dapat membangun model prediktif dengan akurasi tinggi dan mengatasi masalah overfitting pada data training. Banyak penelitian menunjukkan bahwa Random Forest unggul dalam regresi dan klasifikasi dalam berbagai domain, seperti prediksi keuangan, penginderaan jauh, analisis genetik, dan biomedis. Selain itu, RF unggul dibandingkan dengan metode lain..

Random Forests (RF) adalah salah satu teknik pembelajaran mesin yang paling banyak digunakan karena kelebihanannya dalam mengatasi masalah overfitting dan membuat model yang stabil dan akurat, namun RF juga memiliki beberapa kelemahan.

Penggunaan Memori: RF memerlukan penggunaan memori yang signifikan. karena sejumlah besar pohon keputusan dibuat.




Efek Outlier: RF rentan terhadap efek outlier karena modelnya didasarkan pada sejumlah besar pohon keputusan berantai. Jika datanya berbeda secara signifikan, RF dapat memberikan hasil yang tidak akurat.

Menafsirkan Model yang Sulit: Model RF sulit diinterpretasikan karena setiap pohon di RF adalah model yang kompleks.

Oleh karena itu, sulit untuk menjelaskan mengapa RF mengambil keputusan tertentu.

# Random Forest



*Gambar 2. 8 Algoritma Random Forest*

## 2.8 Random Forest With Sparse Random Projection (RFSR)

Random Forests with Sparse Random Projection (RFSR) merupakan algoritma pembelajaran mesin yang menggabungkan dua teknik yaitu random forest dan sparse random proyeksi. RFSR menggunakan konsep ini dan menambahkan Proyeksi Acak Jarang untuk meningkatkan efisiensi desain.

Proyeksi Acak Jarang adalah teknik reduksi dimensi data yang bertujuan untuk mengurangi kompleksitas data dengan memproyeksikan data ke dalam ruang


fitur berdimensi lebih rendah.,[25] di mana setiap dimensi dipilih secara acak dan hanya sedikit dimensi yang digunakan.

Sparse Random Projection dapat digunakan untuk mengurangi dimensi data dalam berbagai aplikasi seperti pengolahan bahasa alami, pengenalan gambar, pengenalan suara, dan lain-lain.[26] Metode ini membantu mengurangi waktu komputasi dan penggunaan memori yang diperlukan untuk melatih model pembelajaran mesin serta meningkatkan performa dan efisiensi model. Dalam RFSR, data diproyeksikan ke dalam ruang objek berdimensi lebih rendah menggunakan proyeksi acak jarang. Setelah itu, setiap pohon keputusan Random Forest dilatih menggunakan data berbeda dan fitur yang dipilih secara acak dalam fungsi baru. Penggunaan RFSR mengurangi kompleksitas waktu dan memori yang diperlukan untuk melatih model sekaligus mempertahankan performa model. Selain itu, RFSR juga mengurangi overfitting karena setiap pohon keputusan dilatih hanya pada subset data yang berbeda dan fitur yang dipilih secara acak.

$$\alpha_{ij} = \sqrt{s} \begin{cases} 1 \text{ with prob } \frac{1}{2s} \\ 0 \text{ with prob } 1 - \frac{1}{s} \\ -1 \text{ with prob } \frac{1}{2s} \end{cases} \text{ typically } S \gg 3$$

Rumus ini menggambarkan suatu variabel yang nilainya bergantung pada probabilitas kemunculan 1,0 dan -1. Dalam rumus diatas probabilitas kemunculan 1 adalah  $1/2s$ , probabilitas kemunculan 0 adalah  $1-1/s$ , dan probabilitas kemunculan -1 adalah  $1/2s$ . [25]

Variabel  $s$  pada umumnya merupakan suatu bilangan yang jauh lebih besar dari 3.



Gambar 2. 9 Algoritma Sparse Random Projection

## 2.9 Teori Random Multimodel Esemble

Algoritma Random Multimodel Ensemble (RME) adalah metode untuk meningkatkan efisiensi atau akurasi model pembelajaran mesin dengan menggabungkan beberapa model berbeda ke dalam ensambel model.[27]. RME menggunakan teknik pengacakan dalam proses pemilihan model ensambel sehingga setiap kali proses pelatihan dijalankan, modelnya berbeda-beda.[28]

Secara rinci, proses algoritma RME terdiri dari beberapa tahap, yaitu:

- Membuat sekumpulan model dasar: Langkah pertama adalah membuat beberapa model dasar dengan algoritma pembelajaran mesin yang berbeda. Setiap model dasar dilatih pada kumpulan data yang sama menggunakan teknik pembelajaran yang berbeda, sehingga menghasilkan model yang berbeda.
- Melakukan pemilihan model: Setelah model dasar terbentuk, langkah selanjutnya adalah memilih model yang digunakan dalam koleksi. Proses pemilihan model dilakukan secara acak dengan mempertimbangkan faktor-faktor seperti kualitas kinerja model, keragaman model.
- Melakukan ensemble model: Model-model yang dipilih digabungkan dalam satu set model. Kombinasi model ini memberikan hasil peramalan yang lebih akurat karena model yang digunakan dalam model ensemble

mempunyai karakteristik yang berbeda-beda, sehingga dapat saling melengkapi kelebihan dan kekurangannya.


- Melakukan proses validasi: Setelah model ensemble terbentuk, langkah selanjutnya adalah proses validasi. Model diuji dengan material yang belum pernah terlihat sebelumnya dan tingkat akurasi dihitung. Dalam proses pemilihan model, RME menggunakan teknik pengacakan sehingga setiap kali pelatihan dilakukan modelnya berbeda-beda. Teknik ini digunakan untuk menghindari overfitting dan memastikan keragaman dalam model.

$$M(Y_{i1}, Y_{i2}, \dots, Y_{in}) = \left[ \frac{1}{2} + \frac{(\sum_{j=1}^n Y_{ij}) - \frac{1}{2}}{N} \right]$$

Di mana  $N$  adalah jumlah model acak, dan  $y_{ij}$  adalah outputnya prediksi model untuk titik data  $i$  dalam model  $j$ . Ruang keluaran menggunakan suara terbanyak untuk  $y_i$  akhir. Oleh karena itu,  $\hat{y}_i$  diberikan sebagai berikut:

$$\hat{Y}_i = [\hat{Y}_{i1} \dots \hat{Y}_{i2} \dots \hat{Y}_{in}]$$

Setelah semua model RDL (RMDL) dilatih, prediksi akhirnya adalah dihitung menggunakan suara mayoritas dari model ini



Gambar 2. 10 Algoritma Random Multimodel Ensemble

### 2.10 Teori Confusion Matrix

Diharapkan bahwa sistem yang melakukan klasifikasi dapat memprediksi dengan benar. Ini berarti pengukuran kinerja sistem untuk mengetahui komponen pengujiannya. Confusion matrix adalah alat pengukuran yang dapat digunakan untuk mengukur kinerja atau tingkat kebenaran proses klasifikasi.[29]. Matriks konfusi dapat digunakan untuk menganalisis seberapa baik pengklasifikasi mengenali kontribusi dari berbagai kategori. Matriks konfusi adalah metode untuk memvisualisasikan kinerja model dalam masalah pemilihan atau klasifikasi kelas. Matriks konfusi merupakan tabel yang berisi hasil dari empat kemungkinan proses klasifikasi yaitu true positive (TP), false negative (FN), dan true negative (TN). Matriks konfusi terdiri dari setiap baris dan kolom yang menunjukkan jumlah prediksi yang benar dan salah.[30] Table *confusion matrix* ditunjukkan pada tabel dibawah ini :

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	<b>Sensitivity</b> $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	<b>Specificity</b> $\frac{TN}{(TN + FP)}$
		<b>Precision</b> $\frac{TP}{(TP + FP)}$	<b>Negative Predictive Value</b> $\frac{TN}{(TN + FN)}$	<b>Accuracy</b> $\frac{TP + TN}{(TP + TN + FP + FN)}$

Gambar 2. 11 Rumus Matrix

Keterangan :

False Positive (FN): adalah ketika model salah memprediksi kelas negatif, artinya model memprediksi kelas negatif tetapi kelas aktual sebenarnya positif.

True Positive (TP): adalah ketika model berhasil memprediksi kelas positif yang benar, artinya model memprediksi kelas positif dan kelas aktual juga positif.

False Positive (FP): adalah ketika model salah memprediksi kelas positif, artinya model memprediksi kelas negatif tetapi kelas aktual sebenarnya negatif.

True negative (TN), false positive (FP), false negative (FN), dan true positive (TP) dapat digunakan untuk mendapatkan nilai presisi, akurasi, dan recall. Nilai akurasi menunjukkan seberapa akurat sistem dapat mengklasifikasikan.

### **Accuracy**

Salah satu metrik evaluasi yang digunakan untuk mengevaluasi seberapa akurat model klasifikasi dalam memprediksi kelas target adalah akurasi, yang dihitung dengan membagi jumlah prediksi benar (True Positives + True Negatives) dengan total jumlah prediksi yang dilakukan (True Positives + False Negatives + False Negatives).

Dalam confusion matrix, accuracy direpresentasikan oleh cell/posisi utama pada matriks, yaitu True Positives dan True Negatives yang terletak pada diagonal utama.  $Accuracy = (TP + TN) / (TP + FP + TN + FN)$ . Semakin besar nilai accuracy, semakin baik performa model dalam memprediksi kelas target.

Persamaan akurasi seperti pada persamaan berikut :

$$Akurasi = \frac{TP+TN}{TP+TN+FP+FN} * 100\%$$

### **Precision**

Keakuratan matriks konfusi adalah rasio jumlah kasus positif yang terdeteksi dengan benar oleh model dibagi dengan jumlah total kasus positif yang terdeteksi oleh model. Secara matematis akurasi dihitung sebagai  $TP / (TP + FP)$ , dimana TP adalah true positif (kasus positif terdeteksi dengan benar) dan FP

adalah false positif (kasus negatif yang merupakan positif palsu). Dengan kata lain, akurasi menunjukkan seberapa akurat model mengklasifikasikan sampel sebagai positif dan menunjukkan kemampuan model untuk menghilangkan kesalahan positif palsu. Semakin tinggi akurasinya, semakin baik model membedakan kasus positif dan negatif.

Persamaan presisi ditunjukkan pada persamaan berikut :

$$\text{Precision} = \frac{TP}{FP+TP} * 100\%$$

### **Recall**

Recall adalah teknik pengujian yang membandingkan jumlah informasi relevan yang diterima sistem dengan jumlah informasi relevan dengan pengumpulan seluruh data. Atau sederhananya, ini adalah metrik evaluasi yang mengukur kemampuan model untuk mengidentifikasi atau menemukan semua hal positif yang sebenarnya. Metrik ini dihitung dengan membagi jumlah positif yang berhasil diidentifikasi oleh model dengan jumlah total positif dalam kumpulan data. Dalam matriks konfusi, recall dapat dihitung dengan membagi jumlah true positif (TP) dengan jumlah true positif (TP + false negative (FN))

Persamaan recall ditunjukkan pada persamaan berikut :

$$\text{Recall} = \frac{TP}{FN+TP} * 100\%$$

### **F measure**

Tabel confusion matrix digunakan untuk mengevaluasi kinerja model dengan menghitung berapa banyak kelas prediksi yang benar dan salah. Empat metrik utama terdiri dari matriks confusion: True Positive (TP), False Positive (FP), False Negative (FN), dan True Negative (TN). Untuk menghitung F-measure dari matriks confusion, dua metode yang umum digunakan adalah:

#### **F1-score**

F1-score merupakan rata-rata harmonis dari precision dan recall yang dihitung sebagai berikut:

$$\text{F1-score} = 2 * ((\text{precision} * \text{recall}) / (\text{precision} + \text{recall}))$$

### F-beta score

F-beta score merupakan rata-rata harmonis dari precision dan recall dengan memberikan bobot yang lebih tinggi pada salah satu metrik (precision atau recall) yang lebih penting. F-beta score dihitung sebagai berikut:

$$\text{F-beta score} = (1 + b^2) * ((\text{precision} * \text{recall}) / ((b^2 * \text{precision}) + \text{recall}))$$

F-measure adalah metrik evaluasi klasifikasi yang menggabungkan presisi (akurasi) dan recall untuk mengukur performa model klasifikasi. Pengukuran F sering digunakan dalam aplikasi yang mencari keseimbangan antara presisi dan perolehan. Dalam perhitungan F-measure dapat dihitung dengan membagi hasil presisi dan recall dengan jumlah presisi dan recall yang kemudian dikalikan dua.

Rumus F-measure dapat dilihat dari persamaan berikut ini :

$$F - \text{measure} = 2 * \frac{\text{precision} \times \text{recall}}{\text{precision} + \text{recall}}$$

### R-Squared (R2)

Nilai R-squared sebesar 0,75 menempatkan variabel independen dalam kategori kuat, nilai R-squared sebesar 0,50 menempatkan variabel independen dalam kategori sedang, dan nilai R-squared sebesar 0,25 menempatkan variabel independen dalam kategori lemah.

$$R^2 = 1 - \frac{SSR}{SST}$$

- SSR adalah jumlah kuadrat residual (sum of squared residuals), yaitu jumlah kuadrat perbedaan antara nilai yang diprediksi oleh model dan nilai sebenarnya dari setiap observasi.
- SST adalah jumlah kuadrat total (sum of squared total), yaitu jumlah kuadrat perbedaan antara nilai observasi dan rata-rata nilai observasi.



### Cohen kappa

Cohen Kappa adalah metode statistik yang digunakan untuk mengukur seberapa baik dua penilai atau pengamat yang berbeda mengklasifikasikan atau menilai data yang sama. Metode ini sangat sering digunakan dalam penelitian klinis, kedokteran, psikologi dan bidang lain yang memerlukan evaluasi .

Koefisien ini mengukur kesepakatan antara dua orang atau lebih dalam menetapkan klasifikasi yang sama pada kumpulan data yang sama.

Rumus Cohen Kappa adalah sebagai berikut:

$$\text{Kappa } (\kappa) = \frac{P_o - P_e}{1 - P_e}$$

Keterangan:

P<sub>o</sub> (Observed Agreement) adalah rasio kecocokan antara dua pengamat atau lebih dalam pemilihan klasifikasi yang sama.

P<sub>e</sub> (Expected Agreement) adalah rasio persetujuan yang diharapkan antara dua pengamat atau lebih jika klasifikasi dilakukan secara acak atau kebetulan semata.

Dalam rangka interpretasi nilai Cohen Kappa, banyak peneliti menggunakan sejumlah kategori, dimulai dari sangat buruk hingga sangat baik. Berikut adalah kategori tersebut:

Kurang dari 0 menunjukkan kesepakatan yang buruk,

0-0,20 menunjukkan kesepakatan yang normal,

0,21–0,40 menunjukkan kesepakatan yang wajar,

0,41–1,60 menunjukkan kesepakatan yang moderat,

0,61–1,80 menunjukkan kesepakatan yang baik,

0,81–1,00 menunjukkan kesepakatan yang sangat baik.

Nilai Cohen Kappa bergantung pada kompleksitas data yang digunakan dan parameter statistiknya.

### ***Mean Absolute Error (MAE)***

Salah satu metrik untuk mengevaluasi model peramalan adalah mean absolute error (MAE), yang mengukur seberapa jauh rata-rata perkiraan model dari nilai sebenarnya yang diharapkan. MAE dihitung dengan mengambil selisih absolut antara nilai sebenarnya dan kemudian mengambil rata-rata dari selisih tersebut.

Secara matematis, formula untuk MAE adalah sebagai berikut:

$$MAE = \frac{1}{M \times N} \sum_x^M \sum_y^N |f1(x, y) - f2(x, y)|$$

Keterangan:

*F1 (x,y) adalah citra sebelum proses*

*F2 (x,y) adalah citra setelah di proses*

*M dan N adalah Panjang baris dan kolom kedua citra tersebut*

### ***Mean Squared Error (MSE)***

Mean squared error (MSE) adalah metrik evaluasi umum yang digunakan dalam model prediktif untuk mengukur seberapa akurat model dapat memprediksi nilai target.

MSE menghitung rata-rata selisih kuadrat antara nilai prediksi dan nilai aktual untuk setiap observasi dalam kumpulan data secara matematis, rumus MSE adalah sebagai berikut:

$$MSE = \frac{1}{M \times N} \sum_x^M \sum_y^N [f1(x, y) - f2(x, y)]^2$$

Keterangan :

*F1 (x,y) adalah citra sebelum proses*

$F2(x,y)$  adalah citra setelah di proses

$M$  dan  $N$  adalah Panjang baris dan kolom kedua citra tersebut

### **Root Mean Squared Error (RMSE)**

Root Mean Squared Error (RMSE) adalah salah satu metrik evaluasi yang digunakan dalam model prediksi untuk mengukur seberapa baik model dapat memprediksi nilai target dengan akurat.

RMSE dihitung dengan mengambil akar kuadrat dari MSE, sehingga memberikan skala nilai yang sama dengan variabel target. Secara matematis, rumus RMSE adalah sebagai berikut:

$$\frac{\sqrt{\sum_{t=1}^n (At - Ft)^2}}{n}$$

### **Mean Absolut Percentage Error (Mape)**

Rata-rata persentase kesalahan absolut (MAPE) adalah metrik evaluasi model prediksi yang mengukur persentase rata-rata kesalahan prediksi relatif terhadap nilai sebenarnya.

MAPE dihitung dengan mengambil nilai absolut selisih antara nilai prediksi dan nilai sebenarnya, dibagi dengan nilai sebenarnya, dan dirata-ratakan hasil seluruh pembagian. Secara matematis, formula untuk MAPE adalah sebagai berikut:

$$\frac{\sum_{t=1}^n |(\frac{At - Ft}{At})| 100}{n}$$

### **Avarage Variance Extracted**

Rata-rata varians yang diekstraksi (AVE) adalah metrik yang digunakan dalam analisis faktor konfirmatori (CFA) untuk mengukur sejauh mana konstruk (variabel) menjelaskan varians dalam indikator terkait.

AVE dihitung dengan mengambil rata-rata kuadrat korelasi antara suatu konstruk dan seluruh indikatornya dan membaginya dengan total varians seluruh indikator yang terkait dengan konstruk tersebut.. Secara matematis, formula untuk AVE adalah sebagai berikut:

$$\frac{(\sum \lambda_i^2) Var f}{(\sum \lambda_i^2) Var + f \sum \theta_{ii}}$$

AVE menghasilkan nilai antara 0 dan 1, dan semakin dekat nilai AVE ke 1, semakin baik konstruk dalam menjelaskan varian dari indikator terkaitnya.

### ***Literature Review***

Telah ada penelitian terdahulu yang dilakukan, yang memberikan wawasan dan pemahaman yang mendalam tentang topik di bidang remote sensing dan penggunaan machine learning untuk pengolahan data geospatial. Berkontribusi baik dalam bentuk konsep, teori, rumus, dan lainnya. Berikut adalah beberapa jurnal penelitian terkait yang digunakan untuk mendukung penelitian ini.

Tabel 2. 3 Literature Review

No	Penulis	Judul	Masalah	Metode	Hasil
1	Tyler M. Tomita,James Browne,Cencheng Shen	Sparse Projection Oblique Randomer Forests	keterbatasan dari forest decision berbasis pemisahan sumbu-miring, yang kehilangan beberapa sifat menguntungkan dari forest decision berbasis pemisahan sumbu-sejajar. Beberapa sifat yang hilang tersebut antara lain ketahanan terhadap dimensi kebisingan yang banyak, interpretabilitas, dan efisiensi komputasi.	penelitian ini memperkenalkan metode baru yang disebut Sparse Projection Oblique Randomer Forests (SPORF). Metode ini menggunakan proyeksi acak yang sangat jarang dengan kombinasi linier dari sebagian kecil fitur. SPORF berhasil meningkatkan akurasi dan mengatasi keterbatasan hutan keputusan berbasis pemisahan sumbu- miring.  Penelitian ini melakukan simulasi eksperimen untuk menguji kinerja SPORF dengan > 100 masalah klasifikasi dengan berbagai dimensi,	Hasilnya menunjukkan bahwa SPORF secara signifikan meningkatkan akurasi dibandingkan dengan algoritme canggih lainnya dalam suite tolok ukur standar untuk klasifikasi. Selain itu, SPORF juga mengurangi efisiensi komputasi dan mempertahankan interpretabilitas. Proyeksi acak yang sangat jarang dapat dimasukkan ke dalam pohon yang diperkuat gradien untuk diperoleh potensi keuntungan serupa

				ukuran sampel, dan jumlah kelas.	
2	Kamal Ahmed , D.A. Sachindra , Shamsuddin Shahid , Zafar Iqbal , Nadeem Nawaz , Najeebullah Khan	Multi-model ensemble predictions of precipitation and temperature using machine learning algorithms	evaluasi kinerja dari Multi-Model Ensembles (MMEs) yang dikembangkan menggunakan algoritma machine learning (ML) dengan kombinasi berbeda dari General Circulation Models (GCMs) yang diurutkan berdasarkan kinerjanya.	Multi-Model Ensemble	RVM menghasilkan MMEs yang menunjukkan variasi kinerja yang lebih kecil di berbagai lokasi, sedangkan ANN menunjukkan fluktuasi kinerja yang besar. Oleh karena itu, KNN dan RVM direkomendasikan untuk pengembangan MMEs di Pakistan daripada SVM dan ANN.
3	Peihao Yang, Linghe Kong, Meikang Qiu	Compressed Imaging Reconstruction with Sparse Random Projection	membahas masalah dalam pemrosesan gambar dari kamera dan monitor yang menghasilkan banyak data gambar setiap hari dalam Internet of Things. Masalahnya adalah bahwa algoritma rekonstruksi yang ada dalam pencitraan terkompresi biasanya	Penulis mengusulkan algoritma rekonstruksi proyeksi acak jarang kombinatorial (SRP) dan menggeneralisasikannya menjadi algoritma terdistribusi baru yang disebut Cloud-SRP (CSRP) yang	Hasil eksperimen pada rekonstruksi pencitraan hantu nyata menunjukkan bahwa algoritme tersebut efektif dan memiliki keunggulan dibandingkan algoritma klasik

			memecahkan masalah pengoptimalan berdasarkan prior tertentu, dengan beban komputasi yang sangat besar dan solusinya biasanya hanya optimal secara lokal	memungkinkan rekonstruksi yang efisien di cloud	dalam eksperimen simulasi.
4	Xu Tan , Jiawei Yang , Susanto Rahardja	Sparse random projection isolation forest for outlier detection	masalah yang muncul dalam menggunakan Isolation Forest untuk mendeteksi outlier dalam data skala besar. Isolation Forest merupakan metode yang cukup populer untuk mendeteksi outlier karena memiliki kompleksitas komputasi yang rendah. Namun, metode ini memiliki kelemahan karena seringkali gagal mendeteksi outlier di beberapa wilayah tertentu.	penulis mengusulkan sebuah metode baru yang disebut Hutan Isolasi berbasis proyeksi acak. Metode ini bekerja dalam dua langkah. Pertama, data diubah menggunakan teknik proyeksi acak. Kemudian, Hutan Isolasi digunakan untuk mengidentifikasi outlier menggunakan data yang diubah. Dalam eksperimen yang dilakukan, metode yang diusulkan berhasil mengungguli 12 detektor outlier canggih yang telah ada.	metode yang diusulkan ini berhasil meningkatkan kinerja Isolation Forest dalam mendeteksi outlier dan dapat digunakan untuk data skala besar dengan kompleksitas komputasi yang rendah.
5	Arnaud Joly, Pierre Geurts, and Louis Wehenkel	Random Forests with Random Projections of the	pengembangan metode ensemble berbasis pohon keputusan untuk masalah	Metode yang dikembangkan mengadopsi konsep	Hasil dari metode tersebut menunjukkan

		Output Space for High Dimensional Multi-label Classification	<p>klasifikasi multi-label. Masalah ini terjadi ketika satu sampel dapat memiliki lebih dari satu label yang harus diprediksi.</p>	<p>proyeksi acak pada output space untuk meningkatkan kinerja metode ensemble berbasis pohon keputusan. Dalam pengujian yang dilakukan menggunakan beberapa data benchmark, metode tersebut menunjukkan bahwa kompleksitas waktu pembelajaran dapat dikurangi tanpa mempengaruhi kompleksitas komputasi dan akurasi prediksi. Selain itu, proyeksi acak pada output space dapat digunakan untuk mencapai trade-off antara bias-variance yang berbeda-beda, sehingga meningkatkan akurasi prediksi sambil mengurangi beban komputasi pada tahap pembelajaran.</p>	<p>potensi untuk meningkatkan kinerja model ensemble berbasis pohon keputusan pada masalah klasifikasi multi-label.</p>
--	--	--------------------------------------------------------------	------------------------------------------------------------------------------------------------------------------------------------	------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	-------------------------------------------------------------------------------------------------------------------------



6	Feng Zhao , Bruce D. Cook , Ryan P. Hanavan	Measuring short-term post-fire forest recovery across a burn severity gradient in a mixed pine-oak forest using multi-sensor remote sensing techniques	pentingnya memahami pemulihan hutan pasca-kebakaran untuk mempelajari dinamika hutan dan siklus karbon global. Penelitian ini ingin menguji apakah penggunaan teknik penginderaan jauh dapat memisahkan pemulihan kanopi dari pemulihan understory dan mengukur tingkat pemulihan hutan pasca-kebakaran yang mencakup gradien besar dalam tingkat keparahan kebakaran dalam skala besar.	Metode yang digunakan adalah gabungan teknik penginderaan jauh multi-sensor (spektroskopi pencitraan udara simultan 1 m dan LiDAR dan citra multi-spektral satelit 2 m) untuk memisahkan pemulihan kanopi dari pemulihan understory. Penelitian dilakukan di hutan pinus-ek campuran di Long Island, NY, tiga tahun setelah kebakaran hebat.	Hasil penelitian menunjukkan bahwa penggunaan teknik penginderaan jauh dapat memisahkan pemulihan kanopi dari pemulihan understory dan memungkinkan untuk mengukur tingkat pemulihan hutan pasca-kebakaran yang mencakup gradien besar dalam tingkat keparahan kebakaran dalam skala besar.
7	Kamran Kowsari, Mojtaba Heidarysafa, Donald E. Brown	RMDL: Random Multimodel Deep Learning for Classification	masalah yang di bahas adalah peningkatan kumpulan data kompleks yang mengharuskan pengembangan metode pembelajaran mesin yang lebih baik untuk melakukan kategorisasi data yang akurat dan kuat. Solusinya adalah dengan mengenalkan Random	Metode yang digunakan adalah RMDL, yaitu pendekatan pembelajaran mendalam yang mengoptimalkan struktur dan arsitektur pembelajaran mendalam secara bersamaan dengan meningkatkan ketahanan dan akurasi melalui ansambel	Hasil pengujian menunjukkan bahwa RMDL menghasilkan kinerja yang lebih baik secara konsisten daripada metode standar pada berbagai tipe data dan masalah klasifikasi,

			Multimodel Deep Learning (RMDL) sebagai pendekatan pembelajaran mendalam baru untuk klasifikasi.	arsitektur pembelajaran mendalam. RDML dapat menerima berbagai jenis data seperti teks, video, gambar, dan simbolik sebagai input.	termasuk MNIST, CIFAR-10, WOS, Reuters, IMDB, dan 20newsgroup. Hal ini menunjukkan bahwa RMDL dapat menjadi solusi yang lebih baik dalam menangani kumpulan data kompleks yang terus meningkat.
8	Meriam Mohajane , Romulus Costache, Firoozeh Karimi, Quoc Bao Pham	Application of remote sensing and machine learning algorithms for forest fire mapping in a Mediterranean area	pengembangan strategi yang akurat untuk mencegah potensi dampak dan meminimalkan terjadinya peristiwa bencana kebakaran hutan di Maroko Utara. Penelitian ini menggunakan lima algoritma pembelajaran mesin hybrid untuk memetakan kerentanan kebakaran hutan dengan menggunakan peta inventarisasi kebakaran hutan dan 10 faktor	Metode yang digunakan dalam penelitian ini adalah pengembangan lima algoritma pembelajaran mesin hybrid baru, yaitu FR-MLP, FR-LR, FR-CART, FR-SVM, dan FR-RF, yang menggunakan peta inventarisasi kebakaran hutan dan 10 faktor penyebab independen sebagai data input. Area di bawah kurva karakteristik operasi	Hasil penelitian menunjukkan bahwa FR-RF memiliki kinerja tertinggi dalam prakiraan kebakaran hutan dengan AUC sebesar 0,989. Ini diikuti oleh SVM-FR dengan AUC sebesar 0,959, MLP-FR dengan AUC sebesar 0,858, CART-FR dengan AUC sebesar 0,847,

			penyebab independen termasuk elevasi, kemiringan, aspek, jarak ke jalan, jarak ke pemukiman, penggunaan lahan, indeks perbedaan vegetasi yang dinormalisasi (NDVI) curah hujan, suhu, dan kecepatan angin.	penerima (ROC) (AUC) dihitung untuk menilai keefektifan model.	dan LR-FR dengan AUC sebesar 0,809. Model hibrida yang dikembangkan baru ini dapat meningkatkan akurasi dan kinerja studi kerentanan kebakaran hutan dan pendekatan tersebut dapat diterapkan ke daerah lain. Hasil penelitian ini dapat memberikan dukungan yang sangat penting bagi pengelolaan ekosistem hutan Mediterania.
9	Fawzi , Nurul Ihsan Husna, Vina Nurul	Sebuah Teori dan Teknik pemrosesan tingkat dasar Landsat-8	Analisis kebumihan membutuhkan pengetahuan dasar terhadap karakteristik citra dan Teknik dasar pengolahannya	Metode yang dilakukan menggunakan Metode Landsat 8 dalam pembahasannya	Pemilihan band pada landsat 8
10	Paz Fernandez, Expectación Delgado, Mónica Lopez-Alonso	GIS environmental information analysis of the Darro River basin as the key for the	analisis informasi tanah dan lingkungan di Lembah Sungai Darro di Granada, Spanyol sebagai pendahuluan untuk	penulis melakukan metode restorasi hutan hidrologi. Analisis tersebut mencakup kondisi morfologi,	otoritas sungai telah memasukkan beberapa tindakan dalam proyek restorasi yang

		management and hydrological forest restoration	restorasi hidrologi dan kehutanan. Analisis dilakukan dengan menggunakan sistem informasi geografis (SIG)	karakteristik tanah dan iklim, vegetasi, dan penggunaan lahan.	bertujuan untuk mengurangi erosi dan membantu memulihkan nilai lingkungan dari lembah sungai ini dan memasukkannya ke dalam kemungkinan rekreasi bagi masyarakat Granada
11	Resul ÇÖMERT Dilek Küçük MATCI Uğur AVDAN	Object based burned area mapping with random forest algorithm	pentingnya memetakan kawasan hutan yang terbakar dengan cepat dan akurat menggunakan metode penginderaan jauh untuk tujuan penilaian kerusakan, analisis risiko kebakaran, dan pengelolaan proses regenerasi hutan.	Metode yang digunakan dalam penelitian ini adalah Object Based Image Analysis (OBIA) dengan menggunakan citra Landsat 8 Terdapat lima langkah dalam penelitian, yaitu segmentasi citra multiresolusi, penghitungan metrik objek gambar, pengembangan model pengklasifikasi Random Forest, penerapan model pada lokasi pengujian untuk	Hasil penelitian menunjukkan bahwa algoritma Random Forest berbasis objek sangat efektif dalam pemetaan kawasan hutan yang terbakar, dengan akurasi keseluruhan mencapai 0,99. Hasil ini dapat berguna dalam menentukan luasan hutan yang terbakar secara cepat dan

				klasifikasi area yang terbakar, dan evaluasi hasil dengan confusion matrix berdasarkan titik sampel acak.	akurat, serta dapat digunakan untuk tujuan pengelolaan hutan dan pemulihan lingkungan.
12	Marcos Ruiz-A´lvarez, Francisco Gomariz-Castillo , and Francisco Alonso-Sarría	Evapotranspiration Response to Climate Change in Semi-Arid Areas: Using Random Forest as Multi-Model Ensemble Method	Masalah yang dijelaskan dalam abstrak ini adalah pentingnya pengembangan metode adaptasi terhadap perubahan iklim menggunakan ansambel besar model iklim, karena ansambel tersebut menyediakan data tambahan yang dapat membantu meningkatkan strategi adaptasi. Untuk memecahkan masalah ini, penulis mengusulkan kerangka kerja untuk mengevaluasi kapasitas prediktif dari 11 metode ansambel multi-model (MME), termasuk acak hutan (RF), untuk memperkirakan referensi evapotranspirasi (ET0) menggunakan 10 model	Metode yang digunakan adalah penggunaan ansambel besar model iklim untuk memperkirakan ET0 dalam skenario historis menggunakan model Hargreaves yang dikalibrasi secara spasial. Hasil dari penelitian ini menunjukkan bahwa ansambel multi-model (MME) menghasilkan hasil yang lebih baik daripada model individual untuk mereproduksi ET0 harian. Dalam validasi, RF menghasilkan lebih akurat daripada MME lainnya dengan efisiensi Kling-Gupta sebesar	Hasil pengujian menunjukkan bahwa tren positif yang signifikan secara statistik diamati sepanjang abad ke-21 untuk RCP8.5, tetapi ini tren stabil di pertengahan abad ini untuk RCP4.5. Pola spasial yang diamati menunjukkan peningkatan ET0 yang lebih besar di hulu dan peningkatan yang lebih kecil di pantai. Dengan demikian, penelitian ini memberikan kontribusi penting

			AR5 untuk skenario RCP4.5 dan RCP8.5.	0,903 dan bias persen absolut sebesar 3,17.	dalam pengembangan strategi adaptasi terhadap perubahan iklim menggunakan ansambel besar model iklim untuk memperkirakan ET <sub>0</sub> .
13	Avetisyan ,DVelizarova, EFilchev L	Post-Fire Forest Vegetation State Monitoring through Satellite Remote Sensing and In Situ Data	dampak kebakaran hutan terhadap lingkungan dan sosial ekonomi, serta pentingnya pemantauan dampak kebakaran dan proses pemulihan pasca kebakaran untuk mengurangi risiko dan dampak peristiwa bencana tersebut. Studi ini berfokus pada wilayah Ardino di Bulgaria tenggara dan mencoba untuk memperkirakan keadaan vegetasi pasca kebakaran dan pengaruhnya terhadap pemulihan vegetasi.	pendekatan pemantauan menggunakan citra penginderaan jauh satelit dan indeks kehijauan, kelembaban, dan tingkat keparahan kebakaran dari Sentinel-2. Data tambahan tentang keadaan vegetasi pra-kebakaran dan kemiringan lereng digunakan untuk melengkapi analisis dan memperkirakan dampaknya terhadap kapasitas pemulihan ekosistem pasca kebakaran.	pendekatan pemantauan menggunakan citra penginderaan jauh satelit dan indeks kehijauan, kelembaban, dan tingkat keparahan kebakaran dapat membantu dalam memperkirakan keadaan vegetasi pasca kebakaran.
14	L. Collins P. Griffioen , G. Newell , A. Mellor	The utility of Random Forests	masalah pemetaan keparahan kebakaran hutan dengan menggunakan data	Metode yang digunakan dalam studi ini adalah Random Forest	pemetaan keparahan kebakaran

		for wildfire severity mapping	satelit dan teknik klasifikasi. Pemetaan keparahan kebakaran yang akurat sangat penting bagi ilmuwan kebakaran dan lembaga pengelolaan lahan di seluruh dunia. Beberapa indeks keparahan kebakaran seperti $\Delta FSI$ dan $\Delta NBR$ banyak digunakan, tetapi terdapat kekurangan seperti kesulitan dalam memetakan kelas keparahan kebakaran yang rendah.	classifier (RF) yang digunakan untuk meningkatkan akurasi pemetaan keparahan kebakaran hutan berbasis satelit di seluruh lanskap heterogen menggunakan citra Landsat. Data pelatihan keparahan kebakaran berbasis titik diperoleh dari enam belas kebakaran hutan besar di Australia tenggara antara tahun 2006 dan 2016. Akurasi prediksi klasifikasi keparahan kebakaran menggunakan $\Delta NBR$ dan RF yang menggabungkan banyak indeks spektral, dinilai menggunakan bootstrapping dan validasi silang. Selain itu, data citra dan penghitungan indeks untuk setiap kebakaran dilakukan di Google Earth Engine (GEE).	menggunakan pengklasifikasi RF dengan memanfaatkan banyak indeks spektral pada citra Landsat dapat meningkatkan akurasi pemetaan keparahan kebakaran hutan berbasis satelit di seluruh lanskap heterogen. Selain itu, menggunakan kerangka kerja klasifikasi berbasis GEE mendukung penerapan operasional pendekatan ini dalam konteks lembaga pengelolaan lahan untuk pembuatan peta keparahan kebakaran secara cepat.
--	--	-------------------------------	----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------

15	Elgar Barboza Castillo,Efrain Y. Turpo Cayo ,Cláudia Maria de Almeida	Monitoring Wildfires in the Northeastern Peruvian Amazon Using Landsat-8 and Sentinel-2 Imagery in the GEE Platform	masalah kehilangan tutupan vegetasi di Amazon yang disebabkan oleh kebakaran hutan dan dampak ekonomi, sosial, dan lingkungan yang ditimbulkannya.	Metode yang digunakan dalam penelitian ini adalah menggunakan indeks spektral untuk menilai area yang terbakar (BA), seperti Normalized Burn Ratio (NBR), Normalized Burn Ratio 2 (NBR2), dan Mid-Infrared Burn Index (MIRBI). Selain itu, digunakan juga indeks lebih lanjut, seperti indeks Pembakaran Inframerah Menengah diferensial (dMIRBI), Rasio Pembakaran Normalisasi diferensial (dNBR), Rasio Pembakaran Normalisasi diferensial 2 (dNBR2), dan Infra Merah Dekat diferensial (dNIR) untuk mengurangi kebingungan antara area yang terbakar dan kelas tutupan lahan lainnya.	Hasil yang diperoleh menunjukkan bahwa BA yang dihitung oleh Sentinel-2 lebih besar dan lebih detail daripada BA yang diekstrak oleh Landsat-8. Metode ini memungkinkan deteksi dan pemantauan tutupan vegetasi yang terbakar dan telah diterapkan pada percobaan di Amazon Peru timur laut. Akurasi untuk Landsat-8 dan Sentinel-2 pada tahun 2017, 2018, dan 2019 bervariasi dari 82,7–91,4% hingga 94,5–98,5%.
----	--------------------------------------------------------------------------------	------------------------------------------------------------------------------------------------------------------------------------------	----------------------------------------------------------------------------------------------------------------------------------------------------------------------	------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------	-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------



Penelitian ini akan berkontribusi di bidang Restorasi Area khususnya deteksi Area sebaran Hotspot , dan berkontribusi dalam pemanfaatan machine learning untuk klasifikasi Area Sebaran Hotspot, terutama penggunaan ekstraksi fitur NBR, Algoritma RF-SRP dan Random Random Multimodel untuk klasifikasi Area Sebaran Hotspot.

### ***Critical Review***

Dengan menggunakan *Harzing Publish Or Perish* di dapatkan 502 jurnal terdahulu yang terindeks google scholar dan scopus dari tahun 2017 sampai dengan tahun 2022 dengan kata kunci Algoritma Forest Restoration dan Normalized Burn Ratio. indeks jurnal ini kemudian dimasukan ke dalam VOSviewer untuk diproses agar menghasilkan keterhubungan antar kata kunci utama di dalam jurnal

*Tabel 2. 4 Jumlah Jurnal per Tahun untuk Critical Analisis*

Tahun	Jumlah Jurnal
2017	39
2018	77
2019	122
2020	122
2021	94
2022	48

*Gambar 2. 12 Critical Analisis dengan Vosviewer*

#### *a. Summary*

Metode penelitian ini menggunakan metode Normalized Burn Ratio dari hasil L. Collins P. Griffioen, G. Newell, A. Mellor, Normalized Burn Ratio (NBR) di gunakan untuk akurasi prediksi klasifikasi keparahan kebakaran hutan berbasis satelit di seluruh lanskap 58awasan5858y menggunakan citra Landsat. menurut Fawzi, Nurul Ihsan Husna, Vina Nurul, Satelit yang digunakan yaitu Landsat 8 dalam pembahasannya. Selain itu menurut Avetisyan, Dvelizarova, Efilchev L, pendekatan pemantauan menggunakan citra penginderaan jauh satelit dan indeks kehijauan, kelembaban, dan tingkat keparahan kebakaran dapat membantu dalam memperkirakan keadaan vegetasi pasca kebakaran sedangkan menurut penelitian lain yang dibahas oleh Paz Fernandez, Expectación Delgado, Mónica Lopez-Alonso, dalam menganalisis informasi menggunakan geographic information system (GIS) dalam mencari kondisi morfologi, karakteristik tanah dan iklim, vegetasi, dan penggunaan lahan. Studi lain membahas masalah kehilangan tutupan vegetasi di Amazon yang disebabkan oleh kebakaran hutan dan dampak ekonomi, sosial, dan lingkungan yang ditimbulkannya oleh Elgar Barboza Castillo, Efrain Y. Turpo Cayo, Cláudia Maria de Almeida, Metode yang digunakan dalam penelitian ini adalah menggunakan indeks 58awasan58 untuk menilai area yang terbakar (BA), seperti Normalized Burn Ratio (NBR). Di dalam penelitian ini menggunakan algoritma Random Forest With Sparse Random Projection yang Menurut Yumang, Luke Clark M. Andrada, Sparse Random Projection secara signifikan meningkatkan akurasi. Selain itu pada penelitian lain menurut Resul ÇÖMERT Dilek Küçük MATCI Uğur AVDAN, memberikan pendapat algoritma Random Forest sangat efektif dalam pemetaan 58awasan hutan yang terbakar ini dapat berguna dalam menentukan luasan hutan yang terbakar secara cepat dan akurat, serta dapat digunakan untuk tujuan pengelolaan hutan dan pemulihan lingkungan. Menurut Tyler M. Tomita, James Browne, Cencheng Shen, SPORF secara signifikan meningkatkan akurasi dibandingkan dengan algoritme lainnya. Menurut Xu Tan, Jiawei Yang, Susanto Rahardja metode Sprase Random

Projection menunjukkan bahwa kompleksitas waktu tanpa mempengaruhi akurasi prediksi. Menurut Kamran Kowsari, Mojtaba Heidarysafa, Donald E. Brown Random Multi Model dianggap sebagai metode pembelajaran mesin yang sangat efektif dan kuat untuk melakukan kategorisasi dan klasifikasi data yang kompleks dan terus meningkat. Selain itu menurut Arnaud Joly, Pierre Geurts, and Louis Wehenkel metode tersebut menunjukkan potensi untuk meningkatkan kinerja model ensemble berbasis pohon keputusan pada masalah klasifikasi multimodel. Dan menurut Marcos Ruiz-A´lvarez, Francisco Gomariz-Castillo , and Francisco Alonso-Sarría, menunjukkan bahwa ansambel multi-model (MME) menghasilkan akurasi hasil yang lebih baik daripada model individual.

Tujuan dari summarize adalah untuk menyampaikan informasi penting secara efisien, singkat dan padat, dan membantu pembaca memahami topik penelitian dengan lebih baik.

#### ***b. Synthesize***

Berdasarkan hasil literature review pada kelima belas penelitian, terdapat empat penelitian mengangkat topik mengenai Sparse Random Projection serta tiga penelitian mengangkat topik mengenai Random Multimodel Ensemble, tiga penelitian mengenai algoritma Random Forest, dua penelitian mengenai algoritma Geographic Information System (GIS), dan tiga topik mengenai Normalized Burn Ratio (NBR). Penerapan algoritma Random Forest With Sparse Random Projection dan Algoritma Random Multimodel Ensemble adalah untuk melihat hasil dengan nilai akurasi yang lebih tinggi yang di jelaskan oleh 10 jurnal . dan penggunaan Normalized Burn Ratio secara garis besar bertujuan untuk mendeteksi potensi kebakaran hutan, Memantau kualitas vegetasi serta juga bisa sebagai penyuluhan pengelolaan risiko kebakaran hutan.

Tujuan melakukan Synthesize dalam penelitian adalah untuk menggabungkan dan menyusun informasi dari berbagai sumber jurnal terkait, dengan tujuan menghasilkan pemahaman yang lebih komprehensif dan mengidentifikasi pola, dan mengambil kesimpulan.

### *c. Comparison*

Tujuan dilakukannya Comparison dalam penelitian adalah untuk membandingkan beberapa variabel atau elemen dalam dua atau lebih penelitian yang relevan untuk mengidentifikasi persamaan dan perbedaan di antara mereka.


Berdasarkan hasil sintesa, didapatkan penelitian yang dilakukan di antaranya menggunakan metode sparse random projection (Sparse Projection Oblique Randomer Forests, Optimization of Vehicle Speed Calculation on Raspberry Pi Using Sparse Random Projection, dan Compressed Imaging Reconstruction with Sparse Random Projection) untuk mengurangi dimensi data yang kompleks dan meningkatkan efisiensi komputasi. Teknik ini memungkinkan untuk mempercepat pemrosesan data tanpa mengorbankan akurasi.

Selain itu, beberapa penelitian (Sparse random projection isolation forest for outlier detection, Random Forests with Random Projections of the Output Space for High Dimensional Multi-label Classification, RMDL: Random Multimodel Deep Learning for Classification, dan The utility of Random Forests for wildfire severity mapping) menggunakan teknik Random Forest dan variasinya untuk klasifikasi dan deteksi anomali dalam data. Teknik ini merupakan salah satu metode populer dalam machine learning karena kemampuan dan kemudahan implementasinya.

Beberapa penelitian lainnya (Measuring short-term post-fire forest recovery across a burn severity gradient in a mixed pine-oak forest using multi-sensor remote sensing techniques, Application of remote sensing and machine learning algorithms for forest fire mapping in a Mediterranean area, Selain itu, beberapa penelitian menggunakan teknik Random Forest dan variasinya untuk mengklasifikasikan dan menemukan anomali dalam data. Beberapa contohnya adalah Random Forests with Random Projections of the Output Space for High Dimensional Multi-label Classification, RMDL: Random Multimodel Deep Learning for Classification, dan The Utility of Random Forests for Wildfire Severity Mapping. Karena kemudahan

penggunaan dan keampuhan, teknik ini menjadi salah satu metode pengajaran mesin yang paling populer. Contoh penelitian tambahan meliputi penggunaan remote sensing dan machine learning algorithms untuk memaparkan hutan di suatu wilayah Mediterranean, pengukuran recovery hutan post-fire dalam jangka pendek di suatu lereng mixed pine-oak forest dengan menggunakan teknik remote sensing multi-sensor, dan pengukuran tingkat keparahan kebakaran di suatu lereng mixed pine-oak forest).

GIS environmental information analysis of the Darro River basin as the key to management and hydrological forest restoration; Object-based burned area mapping with random forest algorithm; Evapotranspiration Response to Climate Change in Semi-Arid Areas: Using Random Forest as Multi-Model Ensemble Method; Monitoring Wildfires in the Northeastern Peruvian Amazon Using Random Forest as Multi-Model Ensemble Method menggunakan teknik pemrosesan citra dan penginderaan jauh untuk memetakan dan memantau kondisi hutan, termasuk pemetaan kebakaran hutan, pemulihan pasca-kebakaran, dan monitoring vegetasi hutan.



*Gambar 2. 13 GAP Penelitian*

Berdasarkan sintesa yang telah dilakukan maka didapatkan dua domain utama dalam penelitian ini untuk menjawab permasalahan pada studi kasus yang diangkat yaitu domain "Algoritma" dan "Forest Restoration". Hasil yang didapatkan untuk domain algoritma dikelompokkan sebagai berikut "Random forest, Random multimodel ". Diperkuat oleh penilitan "Measuring short-term post-fire forest recovery across a burn severity gradient in a mixed pine-oak forest using multi-sensor remote sensing techniques, Application of remote sensing and machine learning algorithms for forest fire mapping in a Mediterranean area" menggunakan teknik pemrosesan citra dan penginderaan jauh untuk memetakan dan memantau kondisi hutan , termasuk pemetaan kebakaran hutan untuk area restorasi di wilayah Kalimantan tengah.

#### **d. Claim**

Tujuan dari claim adalah untuk menyederhanakan dan menyampaikan inti dari penelitian dengan jelas dan singkat. Klaim tersebut membantu pembaca atau audiens untuk memahami esensi dari penelitian tanpa harus membaca keseluruhan laporan atau artikel penelitian.

Kontribusi penelitian yang dilakukan yaitu menggunakan pendekatan indeks *Normalized Burn Ratio (NBR)* yang bertujuan untuk mengklasifikasi area sebaran hotspot menggunakan tingkatan nilai keparahan dari suatu area yang terbakar teknik machine learning dan pemrosesan data digunakan untuk menghasilkan informasi yang berguna dalam memahami kondisi hutan dan mengelola sumber daya alam dengan lebih efektif.

Claim secara Toulmin adalah suatu pernyataan yang menunjukkan posisi atau pendapat yang ingin dibuktikan atau disampaikan. Berikut adalah claim dalam format Toulmin Semantic pada penelitian ini.

Claim (Pernyataan Utama) : Penggunaan algoritma Random Forest With Sparse Random Projection dan Random Multimodel Ensemble, yang

dibantu dengan ekstraksi fitur Normalized Burn Ratio (NBR), dapat memberikan hasil yang akurat dan efektif dalam klasifikasi Area Terbakar.

#### **Justifikasi (Data Pendukung) :**

Penelitian ini menunjukkan kinerja kedua algoritma tersebut dalam pengklasifikasian titik sebaran hotspot. Dalam menampilkan hasil dari algoritma dapat diidentifikasi algoritma mana yang lebih efektif dan akurat dalam klasifikasi area sebaran hotspot.

Penggunaan Normalized Burn Ratio (NBR) sebagai fitur ekstraksi memberikan informasi tentang tingkatan keparahan area yang terbakar . Hal ini dapat memberikan gambaran yang lebih akurat tentang sebaran titik hotspot di area yang pernah terbakar.

Studi kasus yang dilakukan di Katingan Kalimantan Tengah memberikan konteks yang relevan dan spesifik dalam penelitian ini, karena dari hasil penelitian ini dapat menjadi tolak ukur dalam melakukan restorasi dengan cara yang tepat dan akurat

#### **Warrant (Asumsi Dasar) :**

Algoritma Random Forest With Sparse Random Projection dan Random Multimodel Ensemble telah digunakan dan terbukti efektif dalam pengolahan data penginderaan jauh dan pengolahan informasi terkait area yang terbakar.

Normalized Burn Ratio (NBR) memiliki korelasi yang signifikan dengan tingkatan keparahan dari area yang pernah terbakar, sehingga dapat digunakan sebagai fitur ekstraksi yang relevan.



## BAB III

### METODE PENELITIAN


#### 3.1 Lokasi Penelitian

Penelitian ini dilakukan di provinsi Kalimantan Tengah, Ibu Kota Kasongan, Kabupaten Katingan melalui remote sensing dan menggunakan Google Earth Engine dengan titik koordinat :

**[(113.253317789106,-1.0085711562051054],[113.25417609599077,-1.0274509271226115],[113.30979438212358,-1.027107659550121],[113.30876441386187,-1.007541347350219].)**

Total luas lahan yang dijadikan penelitian ini seluas 970,44 hektar. total fungsi lahan di wilayah ini adalah sebagai berikut :

- Pemukiman : 19.285,60 ha
- Industri : 3.156,50 ha
- Sawah : 75.327,50 ha
- Tanah Kering : 109.847,40 ha
- Perkebunan : 37.277,10 ha
- Hutan : 253,816,50 ha
- Hutan Kosong, Rusak : 854.403,80 ha
- Perairan dan lainnya : 193.118,70



*Gambar 3. 1 Lokasi Penelitian*

### 3.2 Sarana Pendukung

*Tabel 3. 1 Tabel Sarana Pendukung*

No	Sarana Pendukung
1	<p>Alat :</p> <ul style="list-style-type: none"> <li>• Perangkat Keras 11th Gen Intel(R) Core(TM) i3-1115G4 @ 3.00GHz 3.00 GHz Ram 8,00 GB Storage SSD 256 GB</li> <li>• Perangkat Lunak OS : Windows 11 Home Single Language Coding Platform : Anaconda3 Coding Language : javascript, Phyton GIS application : Google Earth Engine &amp; USGS Office Profesional Plus 2019 Chrome 103.0.5060.53 Draw.io VOSviewer Harzing Publish Or Perish 8 Mendeley</li> </ul>
2	<p>Bahan :</p> <ul style="list-style-type: none"> <li>• Data Citra Satelit landsat 8 dengan rentang tanggal akuisisi 1 Januari 2020 - 31 desember 2020</li> <li>• Buku dan Jurnal Yang terkait dengan penelitian</li> </ul>

### 3.3 Teknik Pengumpulan Data

Pengumpulan data penelitian ini menggunakan data primer dengan penelitian terdahulu periode (1 Januari 2020 – 31 desember 2020) 6 bulan, Dengan Path/Row : 119/60-62 dan data sekunder berupa studi Pustaka, jurnal, buku dan wawancara.


*Tabel 3. 2 Tabel Hasil Wawancara*

Pertanyaan	Jawaban
Apa faktor penyebab kebakaran hutan di Indonesia, apakah faktor disengaja atau faktor alami?	Bisa keduanya, lebih ke faktor dari alam karena iklim panas , kalau dari faktor manusia yaitu saat orang lalai
Kalau dari faktor manusia, biasanya mereka melakukan perilaku atau	Biasanya yang sering terjadi yaitu melakukan pembakaran sampah di dekat hutan, membuang puntung rokok baik disengaja maupun tidak

Tindakan apa yang bisa menyebabkan kebakaran?	di sengaja dan rendahnya kesadaran masyarakat terhadap kebakaran hutan
Dari kejadian yang pernah terjadi, berapa lama si waktu dari kebakaran itu terjadi?	Ada beberapa lahan yang cukup terbilang lama proses kebakarannya seperti lahan gambut karena proses terjadinya kebakaran itu berada di dalam tanah, serta lama nya proses kebakaran juga di tentukan oleh faktor alam seperti angin dan cuacanya
Ketika kebakaran itu sudah terjadi, pemulihan pasca kebakaran biasanya dilakukan oleh pemerintah atau masyarakat?	Pemerintah bekerjasama dengan masyarakat , pemerintah juga ada pendanaan khusus untuk restorasi, dilakukan pembibitan oleh ditjen Pengendalian Perubahan Iklim (PPI), sedangkan kalua kelapa sakit KLHK dan Kementrian Pertanian
Dari data yang dimiliki oleh KLHK, daerah mana yang paling sering mengalami Karhutla?	Dari data yang dimiliki oleh KLHK, Pulau Sumatra (Palembang dan Lampung) berpotensi paling tinggi dan Kalimantan berada di posisi kedua untuk Potensi Paling tinggi,. Kemudain potensi juga berada di pulau jawa, hutan solo, hutan jati
Ketika pemerintah memiliki data Karhutla, upaya apa yang dilakukan oleh pemerintah untuk mencegah terjadinya Karhutla?	Ditjen Pengendalian Perubahan Iklim (PPI) mengadakan aktifitas rutin untuk mengadakan pengecekan ke daerah yang sering terjadi Karhutla, jika daerah tersebut memiliki indikasi akan terjadinya karhutla, maka akan dilakukan komunikasi serta koordinasi dengan pemerintah setempat

### 3.4 Diagram Alir

Pada dasarnya, metodologi penelitian adalah oprasionalisasi dari epistemology, yang mengkaji tentang urutan tindakan yang diambil supaya pengetahuan yang diperoleh memiliki sifat ilmiah. Diagram alir penelitian, juga dikenal sebagai diagram alir penelitian, digunakan untuk menunjukkan langkah-langkah yang harus dilakukan dalam sebuah penelitian. Diagram ini dapat membantu para peneliti mengatur dan memperjelas proses penelitian mereka, yang membuat komunikasi dan pemahaman antara peneliti, pembimbing, dan tim penelitian lainnya lebih mudah.



Gambar 3. 2 Metodologi Penelitian

Berikut Penjelasan Diagram Alir Penelitian Diatas :


1. Tahap pertama yang dilakukan yaitu identifikasi permasalahan. Identifikasi permasalahan bertujuan untuk mengetahui permasalahan serta untuk mengetahui topik penelitian yang akan di lakukan
2. Setelah identifikasi saatnya menyiapkan kerangka pertanyaan menggunakan metode fishbone dimana didalamnya terdapat pertanyaan yang meliputi cuaca, teknologi, ekosistem dan abiotic yang semuanya meliputi kerangka utama yaitu restorasi pasca kebakaran.
3. Setelah mengetahui permasalahan yang ada maka dilakukan *data collection* untuk mengumpulkan data dari *Google Earth Engine* . data yang

digunakan yaitu citra satelit Landsat 8 dengan rentang waktu 1 Januari 2020 – 31 Desember 2020

4. Tahap berikutnya adalah melakukan *Pre-Processing*, yang didetailkan kedalam dua proses yaitu *Clipping* dengan pemilihan band 5 dan band 7
5. Setelah melakukan *Pre-Processing*, dilakukan ekstraksi fitur menggunakan *Normalized Burn Ratio* yang kemudian menghasilkan dataset.
6. Kemudian dilanjutkan dengan melakukan proses pemodelan dengan menggunakan algoritma *Random Forest With Sparse Random Projection* dan *Random Multimodel Ensemble* untuk melakukan klasifikasi daerah sebaran hotspot pada area terbakar
7. Kemudian dilakukan evaluasi prediksi model terhadap hasil sebelumnya dengan *Confusion Matrix* menggunakan *Accuration, Precision, Recall, F-Measurment, Kappa Score* dan juga menggunakan *Statistikal Analisis* menggunakan Metode *Root Mean Square Error, Mean Squared Error, Mean Absolut Percentage Error* dan *Average Variance Extracted*
8. Tahap selanjutnya yaitu melakukan visualisasi klasifikasi berdasarkan hasil pemodelan menggunakan algoritma *Random Forest With Sparse Random Projection* dan *Random Multimodel Ensemble*.
9. Tahap berikutnya terdapat rekomendasi yaitu klasifikasi daerah sebaran hotspot pada area terbakar.

### 3.5 Timeline Penelitian

Suatu penelitian dilakukan butuh waktu untuk menuntaskannya, dibutuhkan Time line agar jelas dan terlihat waktu mulai dan selesai, berikut adalah timeline pada penelitian ini.




Gambar 3. 3 Timeline Penelitian

## BAB IV

### HASIL DAN PEMBAHASAN

#### 4.1 Analisa Fishbone



*Gambar 4. 1 Diagram Fishbone*

Berdasarkan hasil wawancara dengan narasumber, analisis diagram tulang ikan di atas menunjukkan permasalahan utama yaitu ada empat kategori yang perlu ditelaah lebih lanjut untuk menemukan akar permasalahan. Keempat kategori tersebut adalah cuaca, abiotik, teknologi, dan ekosistem. Oleh karena itu, dibuatlah klasifikasi tingkat kerusakan atau keparahan kebakaran hutan. Sumber daya manusia menemukan kurangnya kesadaran masyarakat tentang kebakaran hutan dan dampaknya, kepentingan perusahaan/individu dalam penggunaan lahan dan kurangnya pendidikan masyarakat. Cuaca diidentifikasi karena iklimnya panas dan angin bertiup terlalu kencang pada musim kemarau atau panas. dan cara dimana proses pemulihan ditentukan hanya dilakukan oleh pemerintah.

#### 4.2 Pengumpulan Data

Data yang digunakan pada penelitian ini yaitu citra yang diperoleh dari satelit Landsat 8 dengan rentang waktu 1 Januari 2020 – 31 Desember 2020. Citra Landsat 8 diperoleh dengan menggunakan *Google Earth Engine (GEE)*

dengan koordinat [113.253317789106,-1.0085711562051054], [113.25417609599077,-1.0274509271226115], [113.30979438212358,-1.027107659550121], [113.30876441386187,-1.007541347350219]. pada penelitian ini *Band* yang digunakan hanya *Band 5* (Near Infrared) dan *Band 7*(*Swir 2*) per masing-masing tanggal akuisisi.

#### 4.2.1 Pre-Processing

Tahap pre-processing adalah tahap dimana dilakukan persiapan data sebelum data data tersebut diolah. Pada tahap pre-processing didetailkan kedalam tahap clipping (pemotongan). Proses clipping pada penelitian ini dilakukan dengan menggunakan google earth engine (GEE) dengan koordinat [113.253317789106,-1.0085711562051054], [113.25417609599077,-1.0274509271226115], [113.30979438212358, 1.027107659550121], [113.30876441386187,-1.007541347350219]. dengan rentang waktu 1 januari 2020 – 31 desember 2020.




*Gambar 4. 2 Pre-Processing*

### 4.3 Ekstrasi Fitur

#### 4.3.1 Ekstrasi Fitur Normalized Burn Ratio (NBR)

Data raster yang telah melalui proses preprocessing dengan menggunakan Google Earth Engine (GEE) diubah menggunakan Normalized Burn Ratio (NBR), suatu indeks vegetasi yang digunakan untuk mengidentifikasi dan memantau daerah yang terdampak oleh kebakaran hutan atau lahan yang diklasifikasikan menjadi 7 spektral warna yang dijelaskan pada table X





*Gambar 4. 3 Visualisasi Normalized Burn Ratio*

*Tabel 4. 1 Burn Saverty Normalized Burn Ratio (NBR)*

<i>Severity Level</i>	<b>Map Legend</b>	<b>NDMI Range</b>
<i>High post-fire regrowth</i>	#808000	- 0.25
<i>Low post-fire regrowth</i>	#6B8E23	-0.25 to – 0.1
<i>Unburned</i>	#00FF00	-0.1 to 0.1
<i>Low-severty brun</i>	#FFFF00	0.1 to – 0.27
<i>Moderate-low severty burn</i>	#FFA500	0.27 to – 0.44
<i>Moderate-high severty burn</i>	#FF0000	0.44 to – 0.66
<i>High-Severty burn</i>	#800080	0.66

#### 4.4 Pemodelan

Pemodelan dalam ilmu data merujuk pada suatu metode sistematis untuk menciptakan representasi matematis atau statistik dari suatu fenomena atau proses dengan memanfaatkan data. Dalam konteks penelitian ini, langkah pemodelan melibatkan penerapan data raster yang telah melalui tahap preprocessing ke dalam model, dan untuk tujuan penelitian ini, digunakan Algoritma Random Multimodel Ensemble dan Random Forest With Sparse Random Projection.

#### 4.4.1 Pemodelan Random Forest With Sparse Random Projection untuk Normalized Burn Ratio

Penerapan algoritma Random Multimodel Ensemble dilakukan dengan menggunakan bahasa pemrograman Python. Dataset yang dipergunakan untuk pemodelan ini berasal dari rentang waktu akuisisi data mulai 1 Januari 2020 hingga 31 Desember 2020, dengan fokus pada ekstraksi fitur Normalized Burn Ratio (NBR).

	id	longitude	latitude	time	B5	B7	QA_PIXEL	SAA	SAZ	VAA	VZA
1	LC08_119061_20200604	113.257345	-1.026325	2020-06-04 02:39:53.025	8384	5386	23888	4598	3484	-8625	374
2	LC08_119061_20200620	113.257345	-1.026325	2020-06-20 02:40:02.528	18547	10457	22280	4546	3600	-7769	379
3	LC08_119061_20200706	113.257345	-1.026325	2020-07-06 02:40:09.999	20333	10116	22280	4726	3607	-7727	379
4	LC08_119061_20200807	113.257345	-1.026325	2020-08-07 02:40:19.014	19471	8761	21824	5681	3274	-8808	364
5	LC08_119061_20200823	113.257345	-1.026325	2020-08-23 02:40:26.051	38105	18351	22280	6480	2983	-8796	368

Gambar 4. 4 Dataset NBR

Data yang awalnya terbagi menjadi dua variabel, x dan y, selanjutnya dipecah kembali menjadi dua bagian, yaitu data pelatihan dan data uji. Pembagian tersebut dilakukan dengan proporsi masing-masing sebesar 70% untuk data pelatihan dan 30% untuk data uji.

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state=10)
```

Gambar 4. 5 Dataset NBR

Setelah data di bagi menjadi 2 yaitu data testing dan training, selanjutnya data tersebut akan dimasukan kedalam model algoritma Random Forest with Sprase Random Projection.

```
[ ] # Sparse Random Projection
    from sklearn.random_projection import SparseRandomProjection

    projector = SparseRandomProjection(n_components=8, random_state=0)
    X_new = projector.fit_transform(X)

[ ] from sklearn.model_selection import train_test_split
    X_train, X_test, y_train, y_test = train_test_split(X_new, y, test_size = 0.3, random_state=10)

[ ] from sklearn.ensemble import RandomForestClassifier

[ ] modelRFSRP = RandomForestClassifier(n_estimators=100, random_state=0)
    modelRFSRP.fit(X_train, y_train)

RandomForestClassifier
RandomForestClassifier(random_state=0)
```

*Gambar 4. 6 Model Algoritma*

Setelah model dibuat, untuk mengetahui tingkat performance dari penerapan algoritma *Random Forest with Sparse Random Projection* terhadap dataset yang digunakan, dilakukan beberapa scoring seperti *R-squared (R2) Score*, *Mean Absolute Error (MAE)*, *Mean Squared Error (MSE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Percentage Error (MAPE)*, *Average Variance Extracted (AVE)*.

R-squared digunakan untuk mengukur kesesuaian model untuk dapat memberikan indikasi seberapa baik model *Random Forest with Sparse Random Projection*, MAE digunakan sebagai metrik evaluasi untuk model prediksi yang mengukur seberapa jauh rata-rata prediksi model dari nilai aktual yang diharapkan, sedangkan untuk MSE digunakan untuk mengetahui nilai rata-rata kesalahan atau error yang dikuadratkan, RMSE digunakan untuk mengetahui seberapa besar kesalahan antara nilai hasil prediksi dengan nilai aktual, MAPE digunakan salah satu metrik evaluasi untuk mengukur persentase rata-rata kesalahan prediksi relatif terhadap nilai aktual. AVE digunakan untuk mengevaluasi *Random Forest with Sparse Random Projection* untuk setiap konstruk dan variable.

```
[ ] # Statistikal Analisis
mse = mean_squared_error(y_test, y_pred)
mae = mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))

mape = np.mean(np.abs((y_test - y_pred) / np.maximum(1, y_test))) * 100
r2 = r2_score(y_test, y_pred)
ave = np.var(y_pred / np.var(y_test))

print("R-squared (R2) Score:", r2)
print("Mean Absolute Error:", mae)
print("Root Mean Squared Error:", rmse)
print("Mean Absolute Percentage Error:", mape)
print("Mean Squared Error:", mse)
print("Average Variance Extracted (AVE)", ave)

R-squared (R2) Score: 0.8304300158362773
Mean Absolute Error: 0.034482758620689655
Root Mean Squared Error: 0.18569533817705186
Mean Absolute Percentage Error: 2.586206896551724
Mean Squared Error: 0.034482758620689655
Average Variance Extracted (AVE) 4.372801372998723
```

*Gambar 4. 7 Scoring RFSRP*

Berdasarkan perhitungan yang telah dilakukan, diperoleh R-Squared (R2) sebesar 0,83%, MAE sebesar 0,03%, RMSE sebesar 0,18%, MAPE sebesar 2,58%, MSE sebesar 0,03%, dan AVE sebesar 4,37%.

Berdasarkan hasil akurasi diperoleh akurasi sebesar 96,55%

```
[ ] Confusion Matrix:
[[ 27  4  0]
 [ 2 275  0]
 [ 0  6 34]]

Classification Report:
              precision    recall  f1-score   support

      0               0.93       0.87       0.90         31
      1               0.96       0.99       0.98        277
      2               1.00       0.85       0.92         40

   accuracy              0.97
  macro avg              0.97
 weighted avg              0.97

Accuracy_score: 96.5517

Kappa Score: 0.8953
```

*Gambar 4. 8 Akurasi RFWSRP*

Hasil clasification report

```

Classification Report:
              precision    recall  f1-score   support

     0           0.93       0.87       0.90         31
     1           0.96       0.99       0.98        277
     2           1.00       0.85       0.92         40

 accuracy              0.97         348
 macro avg           0.97       0.90       0.93         348
 weighted avg        0.97       0.97       0.96         348

Accuracy_score: 96.5517

Kappa Score: 0.8953

```

*Gambar 4. 9 Classifitacion Report*

#### 4.4.2 Pemodelan Random Multimodel Ensemble

Pemodelan algoritma Random Multimodel Ensemble menggunakan bahasa pemrograman phyton. Dataset yang digunakan dalam pemodelan Random Multimodel Ensemble diambil dari periode akuisisi 1 januari 2020 – 31 desember 2020 berdasarkan ekstrasi fitur NBR.

	id	longitude	latitude	time	B5	B7	QA_PIXEL	SAA	SZA	VAA	VZA
1	LC08_119061_20200604	113.257345	-1.026325	2020-06-04 02:39:53.025	8384	5386	23888	4598	3484	-8625	374
2	LC08_119061_20200620	113.257345	-1.026325	2020-06-20 02:40:02.528	18547	10457	22280	4546	3600	-7769	379
3	LC08_119061_20200706	113.257345	-1.026325	2020-07-06 02:40:09.999	20333	10116	22280	4726	3607	-7727	379
4	LC08_119061_20200807	113.257345	-1.026325	2020-08-07 02:40:19.014	19471	8761	21824	5681	3274	-8808	364
5	LC08_119061_20200823	113.257345	-1.026325	2020-08-23 02:40:26.051	38105	18351	22280	6480	2983	-8796	368

*Gambar 4. 10 Dataset NBR*

Data yang telah dibagi kedalam 2 variable x dan y kemudian, dibagi lagi menjadi dua yaitu data training dan data testing dimana masing masing persentase untuk data tersebut yaitu 70% dan 30%.

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3, random_state=10)
```

*Gambar 4. 11 Pembagian Data Training dan Testing RME*

Setelah data dibagi menjadi data training dan data testing, selanjutnya data tersebut dimasukan kedalam model algoritma Random Multimodel Ensemble.

```
[ ] from sklearn.ensemble import RandomForestClassifier

[ ] modelRME = RandomForestClassifier(n_estimators=100, random_state=0)

modelRME.fit(X_train, y_train)

RandomForestClassifier
RandomForestClassifier(random_state=0)

[ ] y_pred = modelRME.predict(X_validation)
```

*Gambar 4. 12 Model Algoritma Random Multimodel Ensemble (RME)*

Setelah model dibuat, untuk mengetahui tingkat performance dari penerapan algoritma Random Multimodel Ensemble terhadap dataset yang digunakan, dilakukan beberapa scoring seperti R-squared (R<sup>2</sup>) Score, Mean Absolute Error (MAE), Mean Squared Error (MSE), Root Mean Squared Error (RMSE), Mean Absolute Percentage Error (MAPE), Average Variance Extracted (AVE).

R-squared digunakan untuk mengukur kesesuaian model untuk dapat memberikan indikasi seberapa baik model Random Multimodel Ensemble, MAE digunakan sebagai metrik evaluasi untuk model prediksi yang mengukur seberapa jauh rata-rata prediksi model dari nilai aktual yang diharapkan, sedangkan untuk MSE digunakan untuk mengetahui nilai rata-rata

kesalahan atau error yang dikuadratkan, RMSE digunakan untuk mengetahui seberapa besar kesalahan antara nilai hasil prediksi dengan nilai aktual, MAPE digunakan salah satu metrik evaluasi untuk mengukur persentase rata-rata kesalahan prediksi relatif terhadap nilai aktual. AVE digunakan untuk mengevaluasi Random Multimodel Ensemble untuk setiap konstruk dan variable.

Berdasarkan perhitungan yang telah dilakukan, diperoleh hasil R-squared 0.89%, MAE 0.02, RMSE 0.15%, MAPE 2.5%, MSE 0.02%, AVE 4.16%

```
[ ] # Stastistik Analisis
mse = mean_squared_error(y_validation, y_pred)
mae = mean_absolute_error(y_validation, y_pred)
rmse = np.sqrt(mean_squared_error(y_validation, y_pred))

mape = np.mean(np.abs((y_validation - y_pred) / np.maximum(1, y_validation))) * 100
r2 = r2_score(y_validation, y_pred)
ave = np.var(y_pred / np.var(y_validation))

print("R-squared (R2) Score:", r2)
print("Mean Absolute Error:", mae)
print("Root Mean Squared Error:", rmse)
print("Mean Absolute Percentage Error:", mape)
print("Mean Squared Error:", mse)
print("Average Variance Extracted (AVE)", ave)

R-squared (R2) Score: 0.896624131804232
Mean Absolute Error: 0.025
Root Mean Squared Error: 0.15811388300841897
Mean Absolute Percentage Error: 2.5
Mean Squared Error: 0.025
Average Variance Extracted (AVE) 4.161751153143795
```

*Gambar 4. 13 Scoring RME*

Berdasarkan Hasil scoring diperoleh akurasi sebesar 97%

```
Confusion Matrix:
[[ 21  2  0]
 [ 0 119  2]
 [ 0  0 16]]

Classification Report:
              precision    recall  f1-score   support

     0       1.00      0.91      0.95         23
     1       0.98      0.98      0.98        121
     2       0.89      1.00      0.94         16

   accuracy       0.97         160
  macro avg       0.96         160
weighted avg       0.98         160

Accuracy_score: 97.5000

Kappa Score: 0.9372
```

*Gambar 4. 14 Akurasi RME*

### Hasil classification report

Confusion Matrix:

```
[[ 21  2  0]
 [  0 119  2]
 [  0  0 16]]
```

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.91	0.95	23
1	0.98	0.98	0.98	121
2	0.89	1.00	0.94	16
accuracy			0.97	160
macro avg	0.96	0.97	0.96	160
weighted avg	0.98	0.97	0.98	160

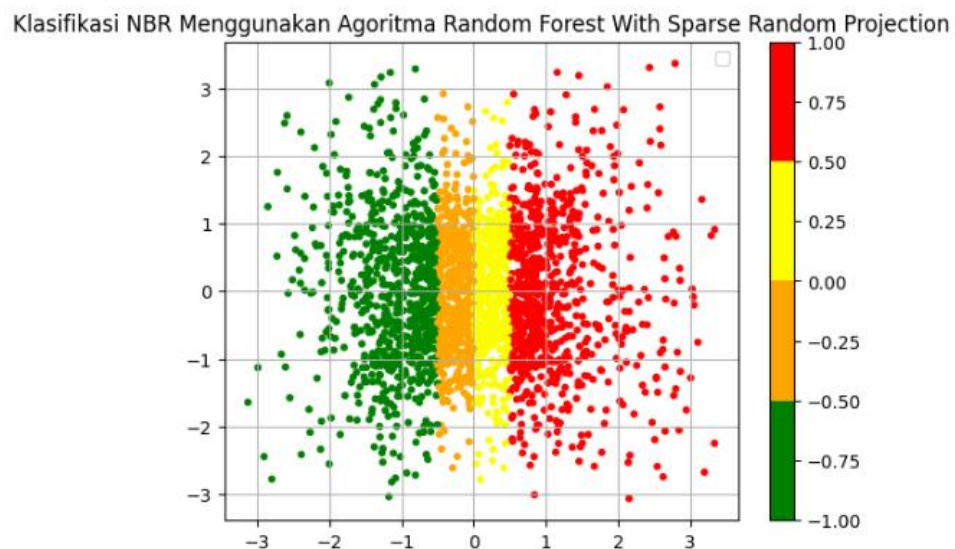
Accuracy\_score: 97.5000

Kappa Score: 0.9372

*Gambar 4. 15 Classification Report*

#### 4.4.3 Visualisasi


Visualisasi dari pengolahan dataset yang sudah dilakukan sebelumnya yang menggunakan algoritma Random Forest with Sparse Random Projection dapat dilihat sebagai berikut. Ini merupakan tampilan scatter plot.




*Gambar 4. 16 Scatter Plot Menggunakan Algoritma RFSRP*




Selain menggunakan scatter plot, didalam penelitian ini juga menggunakan Heatmap



Gambar 4. 17 Heatmap Menggunakan Algoritma RFSRP



Gambar 4. 18 visualisasi scatter plot menggunakan algoritma RME



Gambar 4. 19 Visualisasi Heatmap menggunakan algoritma RME

#### 4.5 Implikasi Bisnis

Implikasi bisnis ini diperoleh dari analisa fishbone, karena terdapat 3 faktor utama yaitu:

1. Faktor utama penyebab kebakaran hutan di Kalimantan adalah aktivitas manusia, cuaca dan teknologi
2. Mengembalikan keadaan tanah yang rusak serta menjadikan struktur dan fungsinya sesuai atau mendekati keadaan semula melalui restorasi.
3. Pemantauan lahan menggunakan teknologi penginderaan jauh untuk mengetahui tingkat keparahan kebakaran dan tingkat vegetasi di area yang terbakar

## **BAB V**

### **KESIMPULAN DAN SARAN**

Pada bagian akhir skripsi ini, peneliti akan mengemukakan kesimpulan dan rekomendasi dari penelitian tersebut. Mereka juga akan mengurai bab-bab di atas mengenai masalah yang diteliti: Analisa Spatial-Temporal untuk Deteksi Sebaran Hotspot pada Area Restorasi Terbakar dengan Penggunaan Algoritma Hutan Sparse Random Projection dan Ensemble Multimodel Random.

#### **5.1 Kesimpulan**

Berdasarkan hasil penelitian ini dapat diambil kesimpulan dari hasil implementasi dan pengujian sebagai berikut :

1. Klasifikasi menggunakan algoritma Random Forest with Sparse Random Projection yang digunakan dalam penelitian ini memperoleh nilai akurasi sebesar 96,55% sedangkan untuk algoritma Random Multimodel Ensemble memperoleh nilai akurasi sebesar 97,50%
2. Hasil Scoring Algoritma Random Multimodel Ensemble terbukti lebih tinggi nilainya dibandingkan dengan Algoritma Random Forest with Sparse Random Projection dengan menunjukan nilai Berdasarkan perhitungan yang telah dilakukan, diperoleh hasil R-squared 0.89%,MAE 0.02,RMSE 0.15%,MAPE 2.5%,MSE 0.02%,AVE 4.16%.
3. Prediksi yang paling baik dari kedua algoritma tersebut yang telah di implementasikan didalam penelitian ini ditunjukan oleh algoritma Random Multimodel Ensemble
4. Hasil dari klasifikasi deteksi sebaran hotpsot didalam penelitian ini bisa diberikan kepada pihak yang berwenang dalam melakukan kegiatan restorasi hutan dengan melampirkan data klasifikasi menggunakan algoritma Random Multimodel Ensemble.

#### **5.2 Saran**

Perlu adanya edukasi kepada masyarakat lokal dan perusahaan swasta mengenai pentingnya peran hutan, karena hutan dinilai sangat penting, termasuk

sebagai penghasil oksigen bagi kelangsungan hidup biologis, penghidupan ekonomi penduduk lokal, dan kelangsungan hidup flora dan fauna langka yang dilindungi. manusia secara tidak langsung bergantung kepada keberadaan ekosistem hutan.

## DAFTAR PUSTAKA

- [1] V. N. I. Nurul Ihsan Fawzi, *Sebuah Teori dan teknik pemrosesan tingkat dasar*, vol. 2, no. 6. 2022. doi: 10.47689/2181-1415-vol2-iss6-pp48-55.
- [2] J. Claudet, C. Loiseau, M. Sostres, and M. Zupan, “Underprotected Marine Protected Areas in a Global Biodiversity Hotspot,” *One Earth*, vol. 2, no. 4, pp. 380–384, 2020, doi: 10.1016/j.oneear.2020.03.008.
- [3] X. Ran, X. Zhou, M. Lei, W. Tepsan, and W. Deng, “A novel K-means clustering algorithm with a noise algorithm for capturing urban hotspots,” *Appl. Sci.*, vol. 11, no. 23, 2021, doi: 10.3390/app112311202.
- [4] A. Joly, P. Geurts, and L. Wehenkel, “Random forests with random projections of the output space for high dimensional multi-label classification,” *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 8724 LNAI, no. PART 1, pp. 607–622, 2014, doi: 10.1007/978-3-662-44848-9\_39.
- [5] L. Collins, P. Griffioen, G. Newell, and A. Mellor, “The utility of Random Forests for wildfire severity mapping,” *Remote Sens. Environ.*, 2018, [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0034425718303328>
- [6] R. Meng, J. Wu, F. Zhao, B. D. Cook, R. P. Hanavan, and S. P. Serbin, “Measuring short-term post-fire forest recovery across a burn severity gradient in a mixed pine-oak forest using multi-sensor remote sensing techniques,” *Remote Sens. Environ.*, vol. 210, no. September 2017, pp. 282–296, 2018, doi: 10.1016/j.rse.2018.03.019.
- [7] L. G. Tereshchenko *et al.*, “Increased Qt Variability Index Is Associated With Mortality in Incident Hemodialysis Patients,” *J. Am. Coll. Cardiol.*, vol. 65, no. 10, p. A338, 2015, doi: 10.1016/s0735-1097(15)60338-2.
- [8] W. Jiao, L. Wang, and M. F. McCabe, “Multi-sensor remote sensing for drought characterization: current status, opportunities and a roadmap for the future,” *Remote Sens. Environ.*, vol. 256, no. December 2020, p. 112313, 2021, doi: 10.1016/j.rse.2021.112313.
- [9] P. Fernandez, E. Delgado, M. Lopez-Alonso, and J. M. Poyatos, “GIS environmental information analysis of the Darro River basin as the key for the management and hydrological forest restoration,” *Sci. Total Environ.*, vol. 613–614, pp. 1154–1164, 2018, doi: 10.1016/j.scitotenv.2017.09.190.
- [10] E. S. Pane, R. Hardianto, Wirdahchoiriah, I. Rangga Bakti, and Y. Permata Bunda, “Pelatihan geographic informatin system (GIS) peta digital melalui google maps dengan menggunakan API key di Fakultas Ilmu Komputer Universitas Pasir Pengaraian (UPP),” *Mejuajua J. Pengabd. pada Masy.*, vol. 2, no. 2, pp. 30–34, 2022, doi: 10.52622/mejuajujabdimas.v2i2.65.
- [11] M. Hemati, M. Hasanlou, M. Mahdianpari, and F. Mohammadimanesh, “A

- systematic review of landsat data for change detection applications: 50 years of monitoring the earth,” *Remote Sens.*, vol. 13, no. 15, 2021, doi: 10.3390/rs13152869.
- [12] E. B. Castillo *et al.*, “Monitoring wildfires in the northeastern peruvian amazon using landsat-8 and sentinel-2 imagery in the GEE platform,” *ISPRS Int. J. Geo-Information*, vol. 9, no. 10, pp. 1–22, 2020, doi: 10.3390/ijgi9100564.
- [13] D. W. Triscowati and A. W. Wijayanto, “Peluang Dan Tantangan Dalam Pemanfaatan Teknologi Penginderaan Jauh Dan Machine Learning Untuk Prediksi Data Tanaman Pangan Yang Lebih Akurat,” *Semin. Nas. Off. Stat.*, vol. 2019, no. 1, pp. 177–187, 2020, doi: 10.34123/semnasoffstat.v2019i1.230.
- [14] B. Wasis, B. H. Saharjo, and R. D. Walidi, “Dampak Kebakaran Hutan Terhadap Flora Dan Sifat Tanah Mineral Di Kawasan Hutan Kabupaten Pelalawan Provinsi Riau,” *J. Trop. Silv.*, vol. 10, no. 1, pp. 40–44, 2019, doi: 10.29244/j-siltrop.10.1.40-44.
- [15] P. T. Tuhulele, “Kebakaran Hutan di Indonesia dan Proses Penegakan Hukumnya Sebagai Komitmen dalam Mengatasi Dampak Perubahan Iklim,” *Supremasi Huk. J. Kaji. Ilmu Huk.*, vol. 3, no. 2, 2014, doi: 10.14421/sh.v3i2.1973.
- [16] A. Melchiorre and L. Boschetti, *Global analysis of burned area persistence time with MODIS data*, vol. 10, no. 5. 2018. doi: 10.3390/rs10050750.
- [17] Y. R. Noor and J. Heyde, *Pengolaan Lahan Gambut Berbasis Masyarakat di Indonesia*. 2016. [Online]. Available: jurnalbumi.com
- [18] Y. Rochmayanto, D. Priatna, and Z. M. Muttaqin, *Strategi dan teknik restorasi ekosistem hutan dataran rawa gambut*, vol. 3, no. August 2021. 2021.
- [19] K. D. Miller, E. Gomes, and D. W. Lehman, “Strategy restoration,” *Long Range Plann.*, vol. 52, no. 5, 2019, doi: 10.1016/j.lrp.2018.10.005.
- [20] P. Yang, L. Kong, M. Qiu, X. Liu, and G. Chen, “Compressed Imaging Reconstruction with Sparse Random Projection,” *ACM Trans. Multimed. Comput. Commun. Appl.*, vol. 17, no. 1, 2021, doi: 10.1145/3447431.
- [21] E. Aflahah, R. Hidayati, R. Hidayat, and F. Alfahmi, “Pendugaan hotspot sebagai indikator kebakaran hutan di Kalimantan berdasarkan faktor iklim Hotspot assumption as a forest fire indicator in Kalimantan based on climate factor,” *J. Nat. Resour. Environ. Manag.*, vol. 9, no. 2, pp. 405–418, 2019, [Online]. Available: <http://dx.http://journal.ipb.ac.id/index.php/jpsl>
- [22] A. Ramadhi and E. I. Putra, “Pendugaan Tingkat Keparahatan Kebakaran Hutan dan Lahan di Hutan Lindung,” no. July, 2021.
- [23] S. Nasery and K. Kaan, “Burn Area Detection and Burn Severity

- Assessment Using Sentinel 2 MSI Data: The Case of Karabağlar District,” *Turkish J. Geosci.*, vol. 1, no. 2, pp. 72–77, 2020, [Online]. Available: <https://dergipark.org.tr/en/pub/turkgeo>
- [24] T. M. Tomita *et al.*, “Sparse projection oblique randomer forests,” *J. Mach. Learn. Res.*, vol. 21, pp. 1–39, 2020.
  - [25] P. Li, T. J. Hastie, and K. W. Church, “Very sparse random projections,” *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, vol. 2006, no. May, pp. 287–296, 2006, doi: 10.1145/1150402.1150436.
  - [26] X. Tan, J. Yang, and S. Rahardja, “Sparse random projection isolation forest for outlier detection,” *Pattern Recognit. Lett.*, 2022, [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0167865522002847>
  - [27] K. Ahmed, D. A. Sachindra, S. Shahid, Z. Iqbal, N. Nawaz, and N. Khan, “Multi-model ensemble predictions of precipitation and temperature using machine learning algorithms,” *Atmos. Res.*, vol. 236, p. 104806, 2020, doi: 10.1016/j.atmosres.2019.104806.
  - [28] K. Kowsari, M. Heidarysafa, D. E. Brown, K. J. Meimandi, and L. E. Barnes, “RMDL: Random multimodel deep learning for classification,” *ACM Int. Conf. Proceeding Ser.*, pp. 19–28, 2018, doi: 10.1145/3206098.3206111.
  - [29] M. F. Nejad and A. Zoratipour, “Assessment of LST and NDMI indices using MODIS and Landsat images in Karun riparian forest,” *J. For. Sci.*, vol. 65, no. 1, pp. 27–32, 2019, doi: 10.17221/121/2018-JFS.
  - [30] A. Luque, M. Mazzoleni, A. Carrasco, and A. Ferramosca, “Visualizing Classification Results: Confusion Star and Confusion Gear,” *IEEE Access*, vol. 10, pp. 1659–1677, 2022, doi: 10.1109/ACCESS.2021.3137630.

## LAMPIRAN

### Lampiran 1 Data Narasumber

Nama	Haswadi,S.E.,M.Si
NIP	196403071991031002
Jabatan	Kepala Sub Bagian Konservasi SDA dan Ekosistem
Alamat	Villa Bintaro Indah Jl Bangka V Blok C 6 No. 3
No.Telfon	087842772002
Foto	



## Lampiran 2 Surat pendukung penelitian

072.423.4.07.01



UNIVERSITAS  
**MERCU BUANA**  
TERAKREDITASI-A

Jakarta, 1 Desember 2023

Nomor : 09-1/126/F/POD/XII/2023  
 Lampiran : .....  
 Perihal : Permohonan Observasi Data

Kepada Yth,  
**Kementrian Lingkungan Hidup dan Kehutanan**  
 Jl. Pejompongan Raya No.1 Rt01/03, Bendungan Hillir Jakarta Pusat, 10270

Up. Haswadi, S.E.,M.Si  
 Kepala Sub Bagian

Dengan hormat,

Dalam rangka memenuhi persyaratan Kurikulum Program Studi Sistem Informasi Fakultas Ilmu Komputer Universitas Mercu Buana, setiap mahasiswa/i yang akan menempuh ujian Sarjana, terlebih dahulu diwajibkan menyelesaikan TUGAS AKHIR, dengan Judul **"Analisis Spatio-Temporal Untuk Deteksi Sebaran Hotspot Pada Restorasi Area Terbakar Menggunakan Algoritma Random Forest With Sparse Random Projection Dan Random Multimodel Ensemble"**.

Sehubungan dengan hal tersebut, bersama ini kami mohon bantuan Bapak/Ibu agar dapat kiranya memberikan data - data yang diperlukan mahasiswa/i kami :

No	Nama	Nim	No_Tlp	Email
1	Ahmad Helmy Nurfaizi	41820010118	087842772001	faizihelmi28@gmail.com

Adapun data yang dibutuhkan adalah sebagai berikut : **Data jumlah kasus kebakaran hutan dan lahan**

Demikian surat permohonan kami, atas perhatian dan bantuan Bapak / Ibu kami ucapkan terima kasih.

Hormat kami,  
**Fakultas Ilmu Komputer**  
 Ketua Program Studi Sistem Informasi



(Dr. Ruci Melyanti, S.Kom., M.Kom)

Tembusan Yth :  
 1. Arsip

Fakultas Ilmu Komputer  
 KAMPUS MENARA BHAKTI  
 Jl. Raya Meruya Selatan No. 1 Kembangan, Jakarta Barat 11650  
 Telp. 021-5840816 (Hunting), Psw : 5700 Fax. 021-5840813  
<http://www.mercubuana.ac.id>, e-mail : [fasikom@mercubuana.ac.id](mailto:fasikom@mercubuana.ac.id)

### Lampiran 3 Hasil Interview

**Laporan Penelitian**  
(Hasil Interview)

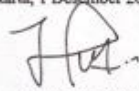
**Narasumber** : Haswadi, S.E., M.Si,  
**Jabatan** : Kepala Sub bagian Konservasi SDA dan Ekosistem  
**Hari/Tgl** : Jum'at, 1 Desember 2023

**Pertanyaan :**

1. Apa faktor penyebab kebakaran hutan di Indonesia, apakah faktor disengaja atau faktor alami?
2. Kalau dari faktor manusia, biasanya mereka melakukan perilaku atau Tindakan apa yang bisa menyebabkan kebakaran?
3. Dari kejadian yang pernah terjadi, berapa lama si waktu dari kebakaran itu terjadi?
4. Ketika kebakaran itu sudah terjadi, pemulihan pasca kebakaran biasanya dilakukan oleh pemerintah atau masyarakat?
5. Dari data yang dimiliki oleh KLHK, daerah mana yang paling sering mengalami Karhutla?
6. Ketika pemerintah memiliki data Karhutla, upaya apa yang dilakukan oleh pemerintah untuk mencegah terjadinya Karhutla?

**Jawaban :**

1. Bisa keduanya, lebih ke faktor dari alam karena iklim panas, kalau dari faktor manusia yaitu saat orang lalai
2. Biasanya yang sering terjadi yaitu melakukan pembakaran sampah di dekat hutan, membuang puntung rokok baik disengaja maupun tidak disengaja dan rendahnya kesadaran masyarakat terhadap kebakaran hutan
3. Ada beberapa lahan yang cukup terbilang lama proses kebakarannya seperti lahan gambut karena proses terjadinya kebakaran itu berada di dalam tanah, serta lama nya proses kebakaran juga di tentukan oleh faktor alam seperti angin dan cuacanya
4. Pemerintah bekerjasama dengan masyarakat, pemerintah juga ada pendanaan khusus untuk restorasi, dilakukan pembibitan oleh Ditjen Pengendalian Perubahan Iklim (PPI), sedangkan kalau kelapa sakit KLHK dan Kementrian Pertanian
5. Dari data yang dimiliki oleh KLHK, Pulau Sumatra (Palembang dan Lampung) berpotensi paling tinggi dan Kalimantan berada di posisi kedua untuk Potensi Paling tinggi. Kemudian potensi juga berada di pulau Jawa, hutan solo, hutan jati
6. Ditjen Pengendalian Perubahan Iklim (PPI) mengadakan aktifitas rutin untuk mengadakan pengecekan ke daerah yang sering terjadi Karhutla, jika daerah tersebut memiliki indikasi akan terjadinya karhutla, maka akan dilakukan komunikasi serta koordinasi dengan pemerintah setempat.

Jakarta, 1 Desember 2023  
  
 Haswadi, S.E., M.Si,